

Preparación y Estandarización de Datos: Mercado Global de IA

Técnicas de limpieza, transformación y enriquecimiento con Pandas (2020-2026)

Dataset: Global AI and Data Science Job Market (Kaggle)

```
{ import pandas as pd }
```

```
import pandas as pd  
df = pd.read_csv('global_ai_jobs.csv')  
df.head()
```

	Data DataFrame				
	Data Scientist	Data Scientist	# Limpieza df.dropna(inplace=True) df['Salary'] = df['Salary'].fillna(df['Salary'].median())		
	Machine Learning Engineer	Machine Learning	# Estandarización df['Country'] = df['Country'].str.upper()		
	Remote	Remote	✓	✓	✓
	Full-time	Full-time	✓	✓	NaN
	2023	2023	85%	£55K	?
	USA	USA	NaN	?	Missing
	Europe	Europe	✓	£55K	N/A
	Python	Python	100% Valid	100% Valid	N/A
	TensorFlow	Tensorf...	✓	✓	N/A
			✓	?	-1

El Activo: Datos del Mercado Laboral de IA

Antes de realizar informes estadísticos, es crítico ejecutar un proceso de 'data cleaning' para asegurar la calidad de la información. Trabajamos con el archivo `ai_jobs.csv`.

Data Schema: `ai_jobs.csv`



`id_del_trabajo`: Identificador único



`título profesional & tipo de empresa`: Datos descriptivos



`país / ciudad`: Ubicación geográfica (con retos de nulidad)



`nivel de experiencia & min_años_de_experiencia`: Requisitos



`salario_mínimo_usd / salario_máximo_usd`: Rangos salariales



`año_publicado`: Temporalidad (2020-2026)

Objetivo: Transformar datos crudos ('**dirty data**') en un **activo fiable** para el análisis.

Fase 1: Importación y Auditoría Estructural

The Action

```
import pandas as pd

# Carga del dataset
df = pd.read_csv('ai_jobs.csv', delimiter=',')

# Auditoría inicial
print(df.shape)
df.head(10)
```

(1260, 9)

id_del_trabajo	título profesional	...	salario_máximo_usd	año_publicado
1	9	título profesional	...	2290

The Result

id_del_trabajo	título profesional	tipo de empresa	pais	ciudad	nivel de experiencia	min_años_de_experiencia	salario_mínimo_usd	salario_máximo_usd	año_publicado
100320_013331	Título profesional	null/dirty	USA	France	clean/valid	6	\$0.00	\$30.00	2010
100220_013392	Complete profesional	null/dirty	USA	Kamana	clean/valid	5	\$0.00	\$50.00	2010
100220_013198	Complete profesional	null/dirty	USA	Kamana	clean/valid	2	\$0.00	\$60.00	2010
100320_013471	Título profesional	null/dirty	USA	France	clean/valid	3	\$0.00	\$90.00	2010
100320_013788	Título profesional	null/dirty	USA	France	clean/valid	3	\$0.00	\$60.00	2010
100720_012528	Professionak profesional	null/dirty	USA	Kamana	clean/valid	4	\$0.00	\$80.00	2010
100350_013798	Título profesional	null/dirty	USA	France	clean/valid	5	\$0.00	\$100.00	2010
100320_013523	Complete profesional	null/dirty	USA	Kamana	clean/valid	2	\$0.00	\$60.00	2010
100320_013681	Título profesional	null/dirty	USA	Kamana	clean/valid	2	\$0.00	\$80.00	2010
100320_012309	Título profesional	null/dirty	USA	France	clesn/valid	3	\$0.00	\$90.00	2010
100320_017193	Título profesional	null/dirty	USA	Aezmaura	clean/valid	1	\$0.00	\$90.00	2020



Visualización Inicial

.head(10) permite ver tipos de datos y errores obvios.




Volumen

.size y .index confirman la dimensión total.

Protocolo de Calidad: Estrategias para Valores Nulos (NaN)

Herramientas de detección: ``isna()`` y ``notna()``


🔍 Detección de Nulos (NaN)



1. Eliminación (``dropna``)

Box text: Enfoque Drástico

- Elimina filas/columnas completas.
- Configurable por umbral (``thresh``).



2. Rellenado (``fillna``) - Técnica Principal

Valor Escalar:

Sustitución fija (ej. 0 o 'Sin datos').

Diccionario:

Valores específicos por columna.

Estadísticos:

Relleno con ``mean()`` o ``median()``.

Interpolación:

Propagación (``bfill``).

Diagnóstico y Reparación: Datos Categóricos

Problema: Nulidad en trabajos remotos.

El Reto: La columna `ciudad` presenta valores nulos. En el contexto de IA, esto suele indicar trabajo remoto, no un error de carga.

La Solución: Relleno con Valor Escalar.

```
# Imputación categórica  
df['ciudad'].fillna('Sin  
especificar/Remoto', inplace=True)
```

Raw

ciudad
New York
London
NaN
Berlin




Clean

ciudad
New York
London
Sin especificar/ Remoto
Berlin

Imputación Estadística: Años de Experiencia

Problema: Nulos en variables cuantitativas (`min\_años\_de\_experiencia`).

```
# Uso de la Mediana para evitar sesgos por outliers  
mediana_exp = df['min_años_de_experiencia'].median()  
df['min_años_de_experiencia'].fillna(mediana_exp, inplace=True)
```



Integridad de los Datos: Eliminación de Redundancias

Duplicidad (Filas)



Función: `drop_duplicates()`

```
# Eliminar registros repetidos
df.drop_duplicates(subset='id_del_trabajo',
                  inplace=True)
```

Garantiza que cada observación sea única.

Irrelevancia (Columnas)



Función: `del`


```
# Eliminar columnas sin valor analítico
del df['id_del_trabajo']
```

Limpieza vertical para optimizar el dataset.

Objetivo: Mantener solo señales únicas y relevantes.

Transformación y Optimización de Tipos


Optimización Temporal



```
# Convertir a formato de fecha  
pd.to_datetime(df['año_publicado'])
```

Facilita el análisis de series temporales (Timeseries).

Optimización de Memoria



```
# Reducir tamaño de datos  
df['tamaño_empresa'].astype('category')
```

Convierte cadenas repetitivas (`object`) a categorías (`category`). Reduce drásticamente el uso de memoria.

Ingeniería de Características (Feature Engineering)

Creación de valor: Cálculo de `salario\_promedio\_usd`

$$\frac{\text{`salario_mínimo`} + \text{`salario_máximo`}}{2} = \text{`salario_promedio_usd`}$$

```
# Creación de nueva variable cuantitativa  
df['salario_promedio_usd'] = (df['salario_mínimo_usd'] + df['salario_máximo_usd']) / 2
```

Segmentación Estratégica: Binning

Herramienta: `pd.cut()`.
Transformación de datos
continuos a discretos.



```
# Segmentación en rangos
python
etiquetas = ['Entrada', 'Competitivo', 'Top']
df['rango_salarial'] = pd.cut(df['salario_máximo_usd'],
                              bins=[0, 50000, 150000, 1000000],
                              labels=etiquetas)
```

Ordenación y Exportación Final

Criterios de Ordenación

-  **Año Publicado**
(- Descendente)
-  **Salario Máximo**
(- Desempate)

```
df.sort_values(by=['año', 'salario'],  
               ascending=[False, False])
```

El Entregable



ai_jobs_clean.csv

Pro Tip: Inter Regular, Slate Grey.

Importante: Usar `index=False` para evitar guardar el índice como columna sucia.

```
df.to_csv('ai_jobs_clean.csv', index=False)
```

Resumen del Pipeline de Datos



El dataset está ahora normalizado y listo para inteligencia de negocios.