

UNIDAD 3: ANÁLISIS EXPLORATORIO DE DATOS

Contenido

CAPÍTULO 1.- IMPORTANCIA DE EDA	2
1.1.- ¿Por qué es crucial el EDA?	2
1.2.- Ejemplo de Código: EDA simple usando Pandas	3
1.3.- Importancia en Big Data.....	5
1.4.- Human Element (elemento humano)	5
1.5.- Risk Mitigation.....	5
1.6.- Ejemplos de Diferentes Sectores	6
1.7.- Comparación de conjuntos de datos	6
1.8.- Fragmentos de código para EDA Visual	7
CAPÍTULO 2.- TIPOS DE DATOS	7
2.1.- Datos Numéricos	7
2.2.- Datos Categóricos.....	9
2.3.- Datos Textuales	10
2.4.- Datos de Series Temporales	11
2.5 Datos Multivariados.....	12
2.6.- Datos Geoespaciales	12
CAPÍTULO 3.- ESTADÍSTICA DESCRIPTIVA.....	14
3.1.- ¿Qué son las estadísticas descriptivas?	14
3.2.- Medidas de Tendencia Central	14
3.3.- Medidas de Variabilidad.....	15
3.4.- ¿Por qué es útil?	16
3.5.- Ejemplo: Examinando datos de ventas.....	16
3.6.- Ejemplo: Examinando reseñas de clientes	17
3.7.- Asimetría y Curtosis	18
3.8.- Conclusiones sobre la importancia del EDA	19



CAPÍTULO 1.- IMPORTANCIA DE EDA

Si piensas en el análisis de datos como una búsqueda del tesoro, entonces el Análisis Exploratorio de Datos (EDA) es el mapa del tesoro que guía tu camino. El EDA proporciona una visión completa de tus datos, incluyendo sus dimensiones, características y patrones ocultos. Al tener este “mapa” de tus datos antes de decidir la mejor “ruta” para encontrar ideas, puedes comprender mejor lo que te espera.

Supongamos que tienes un conjunto de datos que registra el comportamiento del cliente en una tienda minorista. Simplemente mirar los datos sin procesar no te dará ideas reales. Sin embargo, con el EDA, puedes responder preguntas como: ¿Hay un patrón en cuándo aumentan las ventas? ¿Cuál es la edad promedio de los clientes? ¿Las personas que compran el Producto A también tienden a comprar el Producto B? Al encontrar las respuestas a estas preguntas, puedes obtener una mejor comprensión de tus datos y, en última instancia, tomar decisiones más informadas.

1.1. - ¿Por qué es crucial el EDA?

Limpieza de Datos

El Análisis Exploratorio de Datos (EDA) es un paso crucial en cualquier proyecto de ciencia de datos, ya que te permite obtener una comprensión más profunda de tus datos e identificar patrones o relaciones que pueden no ser obvios de inmediato.

Además de ayudarte a identificar valores atípicos, valores faltantes o errores humanos que pueden necesitar atención antes del análisis, el EDA también te permite comprender la distribución de tus datos, evaluar la calidad de tus variables y determinar cualquier problema potencial con tu proceso de recolección de datos. Al realizar un EDA completo, puedes asegurarte de que tus datos estén limpios, sean confiables y estén listos para el análisis, lo que en última instancia conducirá a ideas más precisas y accionables.

Pruebas de Supuestos

Los modelos estadísticos se construyen sobre ciertos supuestos sobre los datos. Estos supuestos a menudo se hacen sobre la distribución y la variabilidad de los datos. Sin embargo, no siempre está claro si los datos cumplen con estos supuestos.

Aquí es donde entra en juego el análisis exploratorio de datos (EDA). El EDA es un proceso de examinar los datos para comprender mejor sus propiedades y detectar cualquier patrón o anomalía que pueda estar presente. Al realizar un EDA, podemos verificar si los supuestos hechos sobre los datos son válidos o no. Esto ayuda a garantizar que los modelos estadísticos que construimos sean precisos y confiables.

Ingeniería de Características



El Análisis Exploratorio de Datos (EDA) es un paso esencial en el proceso de desarrollo de un modelo de aprendizaje automático. Durante esta etapa, es posible que descubras que ciertas características requieren transformación, escalamiento o incluso creación para mejorar la precisión del modelo.

Por ejemplo, puedes encontrar que una característica en particular tiene valores atípicos que necesitan ser identificados y tratados, o que ciertas características están altamente correlacionadas y necesitan ser combinadas en una sola característica. Además, el EDA puede ayudarte a identificar patrones en los datos que pueden informar la selección de modelos y algoritmos apropiados, o llevar al descubrimiento de nuevas variables que pueden ser relevantes para el problema en cuestión.

Selección de Modelo

El Análisis Exploratorio de Datos (EDA) es una fase crítica en la preparación de datos para modelos de aprendizaje automático. Este proceso implica identificar patrones, tendencias y relaciones en los datos que pueden proporcionar ideas valiosas sobre los factores que influyen en la variable de resultado.

Al explorar los datos de esta manera, puedes obtener una comprensión más profunda de la naturaleza subyacente de los datos y identificar cualquier problema potencial que pueda necesitar ser abordado antes del modelado.

Además, los resultados del EDA pueden ayudarte a seleccionar el modelo de aprendizaje automático más apropiado para tu problema particular. Por lo tanto, dedicar tiempo a realizar EDA es un paso esencial en cualquier proyecto de ciencia de datos que involucre aprendizaje automático.

Información para Negocios

El Análisis Exploratorio de Datos (EDA) es una herramienta crucial que puede ayudar a las empresas a obtener ideas valiosas. Al analizar datos, el EDA puede revelar información importante sobre el negocio minorista, como los mejores meses para las ventas, los patrones de compra de los clientes o incluso las ineficiencias en la cadena de suministro. Con esta información, las empresas pueden tomar decisiones basadas en datos para mejorar sus operaciones, aumentar la eficiencia y maximizar las ganancias.

Además, el EDA puede proporcionar una comprensión más profunda del comportamiento, las preferencias y las necesidades de los clientes, lo que puede llevar al desarrollo de mejores productos y servicios que satisfagan sus necesidades. En resumen, el EDA desempeña un papel esencial en ayudar a las empresas a comprender sus datos, obtener ideas valiosas y tomar decisiones informadas para optimizar su rendimiento y éxito.

1.2.- Ejemplo de Código: EDA simple usando Pandas

Para comenzar nuestra exploración de datos, utilizaremos Pandas, una biblioteca de Python versátil y poderosa. Para realizar un análisis preliminar en un conjunto de datos hipotético de ventas minoristas.



El conjunto de datos puede contener información como el nombre del producto, la cantidad vendida y la fecha de compra.

Usando Pandas, podemos cargar y visualizar fácilmente los datos, obtener información sobre las tendencias de ventas e identificar áreas para un análisis más detallado. Por ejemplo, podemos identificar los productos más vendidos o explorar la relación entre el precio y la cantidad vendida. En general, Pandas nos proporciona un conjunto de herramientas valiosas para analizar nuestros datos de ventas minoristas y tomar decisiones comerciales informadas.

Ejemplo

```
import pandas as pd
```

```
# Load the dataset
```

```
df = pd.read_csv('retail_sales.csv')
```

```
# Get a sense of the data
```

```
print(df.head())
```

```
# Summary statistics
```

```
print(df.describe())
```

```
# Checking for missing values
```

```
print(df.isnull().sum())
```

```
# Frequency of sales in each month
```

```
print(df['Month'].value_counts())
```

El Análisis Exploratorio de Datos (EDA) es un componente vital de cualquier proyecto de ciencia de datos. Implica un enfoque sistemático para analizar y comprender los datos, lo cual es esencial para obtener ideas significativas y tomar decisiones informadas. Aunque la afirmación anterior pueda parecer que cubre todo, en realidad el EDA es un proceso complejo que requiere el uso de múltiples herramientas y técnicas. En este capítulo exploraremos algunas de estas herramientas y técnicas con más detalle para darte una mejor comprensión de cómo realizar un EDA exitoso.

Es importante señalar que el EDA no es un proceso que se realiza una sola vez. Más bien, es un proceso iterativo y creativo que requiere un diálogo continuo con tus datos. Cada vez que encuentres nuevos datos, necesitarás revisar tu proceso de EDA para asegurarte de que estás descubriendo nuevas ideas y tomando decisiones informadas. Esto significa que el EDA no es solo un paso en el proceso, sino una conversación continua con tus datos y un componente crítico de cualquier proyecto exitoso de ciencia de datos.



1.3.- Importancia en Big Data

En el mundo actual, donde los datos están en todas partes, la importancia del “Big Data” no puede ser subestimada. Tener una gran cantidad de datos puede ser beneficioso para obtener conclusiones más precisas, pero también puede traer desafíos, como lidiar con el “big noise”. El ruido es la información irrelevante o redundante en los datos que puede distorsionar el análisis.

1.4.- Human Element (elemento humano)

El aprendizaje automático (Machine learning) y la inteligencia artificial han revolucionado el análisis de datos, pero es importante señalar que el “toque humano” sigue desempeñando un papel crucial. Aunque la IA puede procesar grandes cantidades de datos de manera rápida y precisa, carece de la intuición que proviene de años de experiencia y conocimiento.

Durante el análisis exploratorio de datos (EDA), es esencial que los analistas humanos aporten su perspectiva única. Por ejemplo, mientras que una máquina puede tener dificultades para diferenciar entre asociación y correlación en un conjunto de variables, un analista humano puede percibir intuitivamente la relación y ofrecer interpretaciones más matizadas.

En resumen, aunque la tecnología ha impulsado enormemente el campo del análisis de datos, es la experiencia humana la que realmente puede desbloquear todo su potencial.

1.5.- Risk Mitigation

El Análisis Exploratorio de Datos (EDA) puede ser una herramienta de mitigación de riesgos altamente efectiva, especialmente en sectores cruciales como las finanzas y la salud. Al aprovechar el EDA, las industrias pueden identificar posibles problemas o valores atípicos que, de otro modo, podrían pasar desapercibidos. Este proceso puede ayudar a detectar actividades fraudulentas en transacciones financieras, las cuales pueden prevenirse o mitigarse.

Además, en el ámbito sanitario, el EDA puede utilizarse para detectar datos anómalos de pacientes, lo que podría conducir al diagnóstico temprano de afecciones graves. Esto puede facilitar la prestación de asistencia médica oportuna y mejorar los resultados para los pacientes.

Asimismo, el EDA también puede revelar patrones y tendencias que no son evidentes de inmediato, permitiendo que las organizaciones tomen decisiones basadas en datos que mejoren su rentabilidad o su eficacia general.

Example

```
# Simple code to identify outliers in a dataset
import numpy as np

data = np.array([1, 2, 3, 50, 5, 6, 7])
mean = np.mean(data)
std_dev = np.std(data)
```



```
# Identifying outliers
outliers = [x for x in data if abs(x - mean) >= 2 * std_dev]

print("Outliers:", outliers)
```

1.6.- Ejemplos de Diferentes Sectores

La versatilidad del EDA es verdaderamente notable y esto se puede ver en su amplio uso en una variedad de sectores. Por ejemplo, en la industria del comercio electrónico, el EDA desempeña un papel crítico en el seguimiento del comportamiento del usuario, permitiendo a las empresas identificar tendencias y patrones clave que pueden informar las estrategias de marketing y ventas.

De manera similar, en el sector de la salud, el EDA es una herramienta vital para analizar datos importantes de pacientes, como signos vitales, lo que permite a los profesionales médicos tomar decisiones mejor informadas sobre la atención al paciente. Con su capacidad para descubrir ideas y tendencias valiosas en los datos, el EDA se ha convertido en un primer paso esencial para tomar decisiones basadas en datos en muchos sectores e industrias.

1.7.- Comparación de conjuntos de datos

Cuando se trata de análisis de datos, no es raro tener datos de diferentes períodos o departamentos que necesiten ser comparados. El Análisis Exploratorio de Datos (EDA) puede ayudarte a obtener información sobre la compatibilidad de estos conjuntos de datos. Con el EDA, puedes determinar si los conjuntos de datos deben ser analizados por separado o si pueden fusionarse para un análisis más completo.

Además, el EDA también puede brindarte una comprensión más profunda de los conjuntos de datos individuales y ayudarte a identificar cualquier patrón o tendencia subyacente que pueda no ser evidente de inmediato. Al realizar un EDA completo, puedes asegurarte de estar tomando las decisiones más informadas basadas en los datos disponibles, lo que conduce a mejores resultados.

Ejemplo:

```
# Código en Python para comparar dos conjuntos de datos usando medidas estadísticas simples
data1 = np.array([1, 2, 3, 4, 5])
data2 = np.array([2, 3, 4, 5, 6])

mean1, mean2 = np.mean(data1), np.mean(data2)
std_dev1, std_dev2 = np.std(data1), np.std(data2)

print("Media del conjunto de datos 1:", mean1)
print("Media del conjunto de datos 2:", mean2)
print("Standard Deviation of Dataset 1:", std_dev1)
print("Standard Deviation of Dataset 1:", std_dev2)
```



1.8.- Fragmentos de código para EDA Visual

El EDA visual es una herramienta indispensable cuando se trata de analizar datos. De hecho, a menudo se dice que una imagen vale más que mil palabras. Al usar gráficos simples como histogramas, diagramas de caja o gráficos de dispersión, podemos obtener ideas instantáneas sobre los datos e identificar patrones que podrían no ser evidentes al observar los datos en bruto.

Además, el EDA visual puede ayudarnos a detectar valores atípicos, explorar relaciones entre variables e incluso identificar áreas potenciales para análisis adicional. En resumen, no se puede negar que el EDA visual es una técnica poderosa que puede ayudarnos a comprender mejor nuestros datos y tomar decisiones más informadas basadas en nuestros hallazgos.

Ejemplo

```
# Simple code for histogram using matplotlib
import matplotlib.pyplot as plt

data = [2, 3, 4, 4, 5, 6, 6, 7, 8, 9]
plt.hist(data, bins=5, alpha=0.5, color='blue')
plt.xlabel('Value')
plt.ylabel('Frequency')
plt.title('Simple Histogram')
plt.show()
```

Ahora, discutiremos los diferentes tipos de datos que encontrarás comúnmente. Comprender la naturaleza de tus datos es crucial para un EDA efectivo, ya que te guiará en la selección de las herramientas y técnicas apropiadas para la exploración y el análisis. Vamos a categorizar los tipos de datos en grupos principales y proporcionar ejemplos para facilitar su comprensión.

CAPÍTULO 2.- TIPOS DE DATOS

2.1.- Datos Numéricos

Los datos numéricos son un elemento esencial de la investigación científica y representan mediciones cuantitativas de diversos fenómenos. Se dividen en dos tipos principales: datos discretos y continuos. Los datos discretos se refieren a datos que solo pueden tomar ciertos valores específicos y a menudo se obtienen mediante el conteo.

Por ejemplo, el número de autos en un estacionamiento se puede contar, y el resultado es un número discreto. Por otro lado, los datos continuos se refieren a datos que pueden tomar cualquier valor dentro de un rango específico y pueden medirse utilizando una escala. Por ejemplo, el peso de un objeto se puede medir utilizando una balanza, y el resultado es un dato continuo. Ambos tipos de datos son importantes en la investigación científica y pueden proporcionar información valiosa sobre diversos fenómenos.



Datos Discretos

Este tipo de datos consiste en valores distintos y separados que no pueden subdividirse en unidades más pequeñas. A menudo está compuesto por recuentos de cosas que son fácilmente medibles. Un buen ejemplo de datos discretos es el número de empleados en una empresa.

Sin embargo, es importante tener en cuenta que los datos discretos también pueden incluir otros tipos de información como grupos de edad, tallas de zapatos y el número de estudiantes en un aula. El análisis de datos discretos implica determinar la frecuencia de ocurrencia de cada valor e identificar patrones y tendencias que surgen.

Este tipo de datos es extremadamente útil en varios campos como estadística, finanzas y marketing, donde se utiliza para obtener ideas significativas y tomar decisiones informadas.

Datos Continuos

Estos son puntos de datos que pueden tomar cualquier valor dentro de un rango. Los datos continuos pueden expresarse en valores decimales o fraccionarios. Los datos continuos pueden medirse con un alto grado de precisión, por lo que se utilizan con frecuencia en la investigación científica. La altura, el peso y la temperatura son ejemplos de datos continuos.

Además, otros ejemplos de datos continuos incluyen la distancia, el tiempo y la edad. Los datos continuos pueden subdividirse aún más en dos tipos: datos de intervalo y datos de razón. Los datos de intervalo se refieren a datos que no tienen un punto cero verdadero, mientras que los datos de razón se refieren a datos que sí tienen un punto cero verdadero.

Ejemplo

Código de ejemplo para graficar datos discretos y continuos

```
import matplotlib.pyplot as plt
```

```
import numpy as np
```

```
# Datos discretos
```

```
discrete_data = np.random.choice([1, 2, 3, 4, 5], 50)
```

```
plt.subplot(1, 2, 1)
```

```
plt.hist(discrete_data, bins=5)
```

```
plt.title('Datos Discretos')
```

```
import numpy as np
```

```
data = np.random.normal(2, 2, 50)
```

```
bins = 5
```

```
histogram = np.histogram(data, bins=5)
```

```
print(histogram)
```


2.2.- Datos Categóricos

Los datos categóricos son un tipo de datos que se utiliza para representar diferentes características o etiquetas. Los datos categóricos pueden dividirse en dos categorías, a saber, datos nominales y ordinales. Las categorías nominales se utilizan para representar datos que no tienen un orden inherente, como los colores de un arcoíris o las diferentes razas de perros.

Por otro lado, las categorías ordinales se utilizan para representar datos que tienen un orden inherente, como los diferentes tamaños de camisetas (pequeño, mediano, grande). Es importante tener en cuenta que los datos categóricos pueden ser útiles en muchos campos diferentes, como el marketing, las ciencias sociales y el análisis de datos.

Datos Nominales

Los datos nominales no tienen un orden o clasificación natural. Ejemplos incluyen colores, género y tipos de frutas. Los datos nominales son un tipo de datos que no tienen un orden o clasificación natural. Cada valor se considera una categoría distinta y separada en los datos, y cada valor se considera igual. Por ejemplo, cuando recopilamos datos sobre colores, género o tipos de frutas, estamos recopilando datos nominales.

Una característica común en los datos nominales es considerar las categorías que representan los datos como una categoría distinta y separada de las demás, lo que significa que no hay una jerarquía o un orden entre las categorías. Por ejemplo, cuando recopilamos datos sobre los colores de una camiseta, no clasificamos un color como mejor o peor que otro. Más bien, cada color se considera una categoría separada.

Es importante tener en cuenta que los datos nominales no son el único tipo de datos que existen. También existen otros tipos de datos, incluyendo datos ordinales, de intervalo y de razón. Cada uno de estos tipos de datos tiene sus propias propiedades y características únicas, que los hacen útiles en diferentes contextos de análisis.

En resumen, los datos nominales son un tipo de datos que no tienen un orden o clasificación natural. Ejemplos de datos nominales incluyen colores, género y tipos de frutas.

Datos Ordinales

Este tipo de datos tiene un orden natural en el que se organizan las categorías, pero los intervalos entre las categorías no son iguales. Se utiliza para representar datos que implican juicios subjetivos, como las calificaciones de satisfacción del cliente.

En este caso, los datos se pueden clasificar en categorías como “Pobre”, “Promedio” y “Excelente”. Los datos ordinales también se pueden utilizar para representar datos de encuestas donde los encuestados califican su nivel de acuerdo con una afirmación utilizando una escala como “Totalmente en desacuerdo”, “En desacuerdo”, “Neutral”, “De acuerdo” y “Totalmente de acuerdo”. Dado que las



categorías están clasificadas, pero los intervalos entre ellas no son uniformes, los datos ordinales pueden ser complicados de analizar.

Por lo tanto, es importante elegir un método estadístico adecuado para analizar este tipo de datos.

Ejemplo

```
# Example code to plot nominal and ordinal data using bar plots
import seaborn as sns

# Nominal Data
sns.countplot(x=["Apple", "Banana", "Apple", "Orange", "Banana", "Apple", "Orange"])
plt.title('Nominal Data')
plt.show()

# Ordinal Data
sns.countplot(x=["Poor", "Average", "Excellent", "Poor", "Average"])
plt.title('Ordinal Data')
plt.show()
```

2.3.- Datos Textuales

Los datos textuales se refieren a cualquier tipo de datos no estructurados, como publicaciones en redes sociales, comentarios y artículos de noticias. Estos tipos de datos tradicionalmente no se analizaban con EDA, pero con los avances en Procesamiento del Lenguaje Natural (NLP, por sus siglas en inglés), ahora es posible extraer información significativa de los datos textuales.

Las técnicas de NLP pueden utilizarse para identificar patrones y tendencias en grandes cantidades de datos de texto. Además, se puede realizar análisis de sentimientos para comprender el tono emocional del texto y categorizarlo en positivo, negativo o neutral.

Esto permite a empresas y organizaciones comprender mejor la retroalimentación de los clientes y el sentimiento general. Los datos textuales pueden utilizarse para detectar temas y problemas emergentes, lo que puede ayudar a las empresas a mantenerse a la vanguardia y responder de manera proactiva a las tendencias cambiantes.

Ejemplo

```
# Simple example using word frequency
from collections import Counter

text_data = "Exploratory Data Analysis is important for data science."
word_count = Counter(text_data.split())
print("Word Frequency:", word_count)
```



2.4.- Datos de Series Temporales

Los datos de series temporales se refieren a un tipo particular de datos que se recopilan o registran en puntos sucesivos en el tiempo. Estos puntos de datos pueden capturarse en intervalos regulares o irregulares y a menudo se utilizan para analizar patrones o tendencias a lo largo del tiempo.

Una aplicación práctica de los datos de series temporales se encuentra en el mercado de valores, donde se rastrean los precios de las acciones y otros instrumentos financieros a lo largo del tiempo para informar las decisiones de inversión. Otro ejemplo es el de los datos meteorológicos, que se recopilan en intervalos regulares para monitorear los cambios en la temperatura, la precipitación y otros fenómenos meteorológicos.

En los últimos años, el crecimiento explosivo de las redes sociales también ha dado lugar a la creación de vastas cantidades de datos de series temporales. Por ejemplo, los datos de actividad de Twitter pueden analizarse para rastrear cambios en la opinión pública o para identificar tendencias y temas emergentes.

En general, el uso de datos de series temporales en una variedad de campos se ha vuelto cada vez más importante, ya que proporciona una herramienta valiosa para comprender y predecir patrones a lo largo del tiempo.

Ejemplo

```
# Simple time-series plot
import pandas as pd

time_series_data = pd.DataFrame({
    'Date': pd.date_range(start='1/1/2022', periods=10, freq='D'),
    'Stock_Price': [1, 2, 3, 4, 3, 4, 5, 6, 7, 8]
})

time_series_data.plot(x='Date', y='Stock_Price', kind='line')
plt.title("Time Series Data")
plt.show()
```

Entender los diversos tipos de datos es un aspecto fundamental del análisis exploratorio de datos (EDA, por sus siglas en inglés). Implica aprender a visualizar y gestionar datos de manera efectiva, lo cual es crucial para tu trayectoria de exploración de datos. En las secciones siguientes, proporcionaremos ideas detalladas sobre cómo cada tipo de datos requiere un enfoque distinto para un análisis efectivo.

Al dominar estas técnicas, estarás bien preparado para manejar conjuntos de datos intrincados y sacar conclusiones significativas de ellos. Esto te permitirá obtener ideas valiosas y tomar decisiones informadas en diversos campos, incluyendo negocios, finanzas, atención médica y más



2.5 Datos Multivariados

En el análisis exploratorio de datos (EDA), los **datos multivariados** se refieren a conjuntos de datos que contienen **más de dos variables**. Analizar varias variables simultáneamente permite descubrir **patrones, tendencias o correlaciones** que no serían evidentes si se estudiaran de forma aislada.

Una técnica común para visualizar relaciones entre múltiples variables es el **pairplot**, que genera una **matriz de gráficos de dispersión** para cada par de variables. Esto facilita:

- Identificar relaciones lineales o no lineales.
- Detectar correlaciones.
- Observar posibles valores atípicos.

Además de los pair plots, las técnicas de análisis de datos multivariados se pueden utilizar para desarrollar modelos que pueden predecir resultados basados en la relación entre múltiples variables. Estos modelos pueden utilizarse para prever tendencias, identificar patrones y tomar decisiones informadas. Al utilizar el análisis de datos multivariados, uno puede obtener una comprensión más completa de conjuntos de datos complejos y tomar decisiones informadas basadas en las relaciones entre múltiples variables.

A continuación, se muestra un ejemplo en Python utilizando la librería **Seaborn** para crear un pairplot:

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd
# Create a DataFrame
df = pd.DataFrame({
    'Height': [5.9, 5.8, 5.6, 6.1, 5.7],
    'Weight': [75, 80, 77, 89, 94],
    'Age': [21, 22, 20, 19, 18]
})
# Create a pairplot
sns.pairplot(df)
plt.suptitle('Multivariate Data Visualization', y=1.02)
plt.show()
```

En el pairplot anterior, puedes examinar visualmente cómo **Altura, Peso y Edad** interactúan entre sí. Esto puede ser muy útil para identificar patrones o anomalías en los datos.

2.6.- Datos Geoespaciales

Los datos geoespaciales son un tipo de datos que contienen información sobre la ubicación geográfica de objetos o eventos. Este tipo de datos es altamente valioso ya que proporciona una amplia gama de información que puede ser utilizada en diversos campos.



Por ejemplo, puede proporcionar información detallada sobre los patrones climáticos de una región particular, la ubicación de los recursos naturales y la densidad de población de un área. Estos datos también pueden ser utilizados para estudiar el impacto de las actividades humanas en el medio ambiente y desarrollar estrategias para mitigarlos.

La complejidad de los datos geospaciales puede variar ampliamente, desde simples coordenadas de latitud y longitud de una ciudad hasta un mapa de varias capas que contiene una amplia gama de información. En general, los datos geospaciales son una herramienta esencial en muchas industrias y desempeñan un papel crucial en nuestra comprensión del mundo que nos rodea.

Aquí tienes un ejemplo simple que representa las coordenadas geográficas (latitud y longitud) de tres ciudades: Nueva York, Los Ángeles y Chicago.

```
import matplotlib.pyplot as plt

# Sample coordinates: [latitude, longitude]
locations = [
    [40.7128, -74.0060], # New York
    [34.0522, -118.2437], # Los Angeles
    [41.8781, -87.6298], # Chicago
]

# Unzip the coordinates
latitudes, longitudes = zip(*locations)
# Create a scatter plot
plt.scatter(longitudes, latitudes)
plt.xlabel("Longitude")
plt.ylabel("Latitude")
plt.title("Geospatial Data Visualization")
plt.show()
```

Este es un ejemplo básico que se puede ampliar de varias maneras para mejorar su funcionalidad y utilidad. Por ejemplo, puedes incluir capas adicionales como carreteras, puntos de referencia u otros datos relevantes que podrían ser útiles para tu aplicación específica.

Al introducir estos tipos adicionales de datos, puedes obtener una comprensión más completa de los tipos de datos que podrías encontrar en escenarios reales de análisis geoespacial. Esto puede ayudarte a prepararte mejor para tales escenarios y desarrollar modelos de análisis de datos más precisos y fiables. Además, al incorporar más capas de datos en tu análisis, también puedes aumentar la profundidad y complejidad de tu análisis, lo que te permitirá descubrir ideas y tendencias que podrían no ser evidentes en un análisis más básico.



CAPÍTULO 3.- ESTADÍSTICA DESCRIPTIVA

Bienvenido a esta sección dedicada al apasionante campo de las **Estadísticas Descriptivas**, un pilar fundamental dentro del Análisis Exploratorio de Datos (EDA). Si alguna vez has cursado una asignatura introductoria de estadística o ciencia de datos, seguramente este concepto ya te resulte familiar.

Las estadísticas descriptivas reúnen un conjunto de métodos y herramientas que permiten **resumir y describir** los aspectos más relevantes de un conjunto de datos. Gracias a ellas, es posible obtener una visión más profunda de la información, detectar patrones, identificar valores atípicos y comunicar conclusiones de forma clara y efectiva.

A pesar de su nombre técnico, las estadísticas descriptivas son accesibles y muy útiles para mejorar tus capacidades de análisis. Te invito a adentrarte en este tema y descubrir cómo pueden ayudarte a comprender mejor tus datos.

3.1.- ¿Qué son las estadísticas descriptivas?

Las estadísticas descriptivas constituyen una forma de **sintetizar datos de manera significativa**, permitiendo obtener una visión rápida del conjunto sin necesidad de revisar cada valor individual. Funcionan como una “primera mirada” que facilita entender la estructura general de los datos antes de profundizar en análisis más complejos.

Es como conocer a alguien por primera vez. Obtienes una idea general de quién es a partir de su apariencia, su forma de hablar y algunos datos básicos. Del mismo modo, las estadísticas descriptivas ofrecen una visión general del conjunto de datos, permitiéndote entender sus rasgos principales y tomar decisiones fundamentadas.

Además, las estadísticas descriptivas permiten identificar patrones y relaciones dentro de los datos, lo cual resulta útil para anticipar tendencias o apoyar decisiones informadas. En conjunto, constituyen una herramienta poderosa para interpretar información y forman una parte esencial de cualquier proceso de análisis de datos.

3.2.- Medidas de Tendencia Central

La tendencia central es un concepto estadístico que describe el “centro” de un conjunto de datos, es decir, el punto alrededor del cual se agrupan la mayoría de los valores. Para comprenderla, es fundamental conocer tres medidas principales:

- **Media:** también llamada promedio. Se obtiene sumando todos los valores y dividiéndolos entre la cantidad total de datos. Es útil porque incorpora todos los valores y ofrece un único número representativo del centro.



- **Mediana:** es el valor que ocupa la posición central cuando los datos están ordenados. Si el número de valores es par, la mediana es el promedio de los dos valores centrales. Es especialmente útil porque no se ve tan afectada por valores extremos como la media.
- **Moda:** es el valor o valores que aparecen con mayor frecuencia en el conjunto de datos. Si ningún valor se repite, entonces no existe moda. Es útil para identificar qué valores son más comunes.

En resumen, comprender la tendencia central y estas tres medidas clave ayuda a obtener una visión más clara de la distribución de los datos y aporta información valiosa para análisis posteriores.

```
import pandas as pd

# Create a DataFrame
df = pd.DataFrame({
    'Age': [25, 30, 35, 40, 45, 50, 55, 60, 65, 70]
})

# Calculate mean, median, and mode
mean_age = df['Age'].mean()
median_age = df['Age'].median()
mode_age = df['Age'].mode()

print(f"Mean Age: {mean_age}")
print(f"Median Age: {median_age}")
print(f"Mode Age: {mode_age.tolist()}")
```

3.3.- Medidas de Variabilidad

Para obtener una comprensión más profunda de los datos, puedes explorar diversas medidas de dispersión que te ayuden a comprender cuán dispersos están los datos. Además del rango, que es la diferencia entre los valores máximo y mínimo, existen otras medidas que proporcionan información valiosa.

Una de esas medidas es la **varianza**, que calcula qué tan lejos está cada valor del conjunto de datos respecto a la media. Esta métrica es especialmente útil porque considera todos los valores y cuantifica cuánto varían en relación con la media.

Otra medida estrechamente relacionada es la **desviación estándar**, que es simplemente la raíz cuadrada de la varianza. Esta medida resulta muy útil para obtener una visión más clara de la dispersión de los datos.

Al explorar diferentes medidas de dispersión, puedes obtener una comprensión más completa del conjunto de datos y descubrir patrones o ideas que no son evidentes al observar únicamente los valores en bruto.



Así es como puedes calcular estas medidas:

```
# Calculate range, variance, and standard deviation
range_age = df['Age'].max() - df['Age'].min()
variance_age = df['Age'].var()
std_deviation_age = df['Age'].std()

print(f"Range of Age: {range_age}")
print(f"Variance of Age: {variance_age}")
print(f"Standard Deviation of Age: {std_deviation_age}")
```

3.4.- ¿Por qué es útil?

Las estadísticas descriptivas son una herramienta fundamental en el análisis de datos. Ofrecen un resumen claro y conciso de la información, lo que facilita su interpretación y la extracción de conclusiones. Ya sea analizando el comportamiento de clientes o revisando historiales médicos, estas estadísticas pueden revelar patrones, tendencias y relaciones importantes dentro de los datos.

Aunque Python es una excelente opción para realizar estos cálculos, también existen otras herramientas como Excel, R o software estadístico especializado. Sin embargo, comprender bien los conceptos básicos es esencial para aplicarlos en cualquier entorno y tomar decisiones informadas basadas en los datos. Con este conocimiento, podrás analizar información con seguridad y obtener ideas valiosas que te ayuden a mejorar tus decisiones.

3.5.- Ejemplo: Examinando datos de ventas

Imagina que cuentas con un conjunto de datos que recoge los ingresos mensuales de tu empresa durante el último año. Quieres identificar tendencias centrales y variaciones dentro de esos valores.

Así podrías hacerlo en Python:

```
# Sample sales data for the past 12 months (in 1000s)
sales_data = pd.DataFrame({
    'Month': ['Jan', 'Feb', 'Mar', 'Apr', 'May', 'Jun', 'Jul', 'Aug', 'Sep', 'Oct', 'Nov', 'Dec'],
    'Revenue': [200, 220, 250, 275, 300, 320, 350, 370, 400, 420, 450, 475]
})

# Calculate mean, median, and mode
mean_sales = sales_data['Revenue'].mean()
median_sales = sales_data['Revenue'].median()
mode_sales = sales_data['Revenue'].mode()

print(f"Mean Revenue: {mean_sales}k")
print(f"Median Revenue: {median_sales}k")
print(f"Mode Revenue: {mode_sales.tolist()}k")
```



3.6.- Ejemplo: Examinando reseñas de clientes

Supongamos que estás revisando las opiniones de los clientes en una escala del 1 al 5, y te gustaría saber cómo se distribuyen las calificaciones, cuán variables son y dónde se encuentra la tendencia central.

```
# sample customer review ratings
reviews_data = pd.DataFrame({
    'customerID': range(1, 9),
    'Rating': [5, 4, 5, 2, 5, 3, 2, 1]
})

# Calculate mean, median, and mode
mean_rating = reviews_data['Rating'].mean()
median_rating = reviews_data['Rating'].median()
mode_rating = reviews_data['Rating'].mode()

# Calculate range, variance, and standard deviation
range_rating = reviews_data['Rating'].max() - reviews_data['Rating'].min()
variance_rating = reviews_data['Rating'].var()
std_deviation_rating = reviews_data['Rating'].std()

print(f'Mean Rating: {mean_rating}')
print(f'Median Rating: {median_rating}')
print(f'Mode Rating: {mode_rating.tolist()}')
print(f'Range of Ratings: {range_rating}')
print(f'Variance of Ratings: {variance_rating}')
print(f'Standard Deviation of Ratings: {std_deviation_rating}')
```

Al ejecutar estas simples líneas de código, obtendrás una comprensión completa del conjunto de datos con el que estás trabajando. Este es un importante primer paso para analizar tus datos y obtener ideas valiosas. Las estadísticas descriptivas que se muestran en este código pueden permitirte tomar conjuntos de datos complejos y grandes y simplificarlos en ideas significativas en las que puedes actuar.

De hecho, las estadísticas descriptivas son una herramienta esencial para cualquier analista de datos o investigador. Proporcionan una forma de resumir y comunicar aspectos clave de los datos, como la tendencia central, la variabilidad y la forma de tu conjunto de datos. Al comprender estas características clave de tus datos, puedes comenzar a identificar tendencias y patrones que pueden estar ocultos dentro de los datos.

Entonces, siéntete libre de ajustar los ejemplos de código con tus datos para ver qué tipo de tendencias y patrones surgen. ¡Puede que te sorprendas con lo que descubras! Recuerda que cuanto más explores tus datos utilizando estadísticas descriptivas, más ideas obtendrás y más informadas serán tus decisiones.



3.7.- Asimetría y Curtosis

La **asimetría** es una medida estadística que permite determinar el grado de simetría en una distribución.

Un valor cercano a 0 indica que los datos son aproximadamente simétricos. Si la asimetría es **negativa**, se dice que los datos están *sesgados hacia la izquierda*, lo que significa que la cola izquierda es más larga que la derecha. Si la asimetría es **positiva**, los datos están *sesgados hacia la derecha*, indicando que la cola derecha es más larga que la izquierda.

La **curtosis**, por su parte, mide la “colitud” de la distribución. Un valor de curtosis **mayor que 3** (comparado con una distribución normal) indica la presencia de más valores atípicos: los datos están más concentrados alrededor de la media y menos dispersos en las colas.

Un valor **menor que 3** sugiere menos valores atípicos y una mayor dispersión hacia las colas. La curtosis ayuda a comprender la forma de la distribución y la presencia de valores extremos.

Aquí tienes un ejemplo rápido en Python usando los datos de ventas:

```
# Calculate skewness and kurtosis
skewness = sales_data['Revenue'].skew()
kurtosis = sales_data['Revenue'].kurt()

print(f"Skewness of Revenue: {skewness}")
print(f"Kurtosis of Revenue: {kurtosis}")
```

Incorporar estas métricas puede ofrecer una visión más completa de tus datos y ayudarte a tomar decisiones mejor fundamentadas.

Ejercicios Prácticos para el Capítulo 3.1

Deberás realizar un cuaderno de Jupiter, MUY BIEN EXPLICADO CON COMENTARIOS EN MARKDOWN.

Ejercicio 1: Comprender la Importancia del EDA

Carga un conjunto de datos de tu elección. Realiza exploraciones iniciales como `.head()`, `.info()` y `.describe()` para familiarizarte con su estructura.

Ejercicio 2: Identificar Tipos de Datos

Identifica al menos dos columnas en tu conjunto de datos que contengan datos categóricos y dos que contengan datos numéricos.

Ejercicio 3: Calcular Estadísticas Descriptivas

Calcula la media, mediana y desviación estándar de una columna numérica en tu conjunto de datos.



Ejercicio 4: Comprender la Asimetría y la Kurtosis

Calcula la asimetría y la kurtosis para una columna numérica en tu conjunto de datos.

3.8.- Conclusiones sobre la importancia del EDA

En ESTOS APARTADOS hemos recorrido el mundo del análisis exploratorio de datos (EDA), desde su papel esencial en cualquier proyecto de ciencia de datos hasta las herramientas prácticas que nos ayudan a entender mejor la información que tenemos delante. El EDA es mucho más que una etapa técnica: es el momento en que los datos empiezan a hablar, a mostrar patrones, anomalías y relaciones que nos orientan hacia decisiones más acertadas y modelos más sólidos.

Al principio vimos por qué no conviene saltarse esta fase. Igual que un pintor no empieza a aplicar color sin antes trazar el boceto, un buen analista de datos necesita explorar antes de modelar. Observar los datos con atención desde el inicio nos permite entender qué tenemos entre manos y cómo abordarlo con criterio.

También hablamos sobre los distintos tipos de datos (categóricos y numéricos) y cómo reconocerlos nos ayuda a elegir las técnicas adecuadas. Saber qué tipo de información estamos manejando evita errores y hace que el análisis sea más ágil, sobre todo cuando trabajamos con conjuntos de datos grandes o complejos.

Más adelante, nos adentramos en las estadísticas descriptivas. Vimos cómo medidas como la media, la mediana, la desviación estándar, la asimetría y la curtosis nos permiten resumir grandes volúmenes de datos en cifras que realmente dicen algo. Y lo mejor: aprendimos a calcularlas con Python, lo que nos da herramientas concretas para aplicar todo esto en la práctica.

Finalmente, los ejercicios del capítulo te invitan a poner en marcha lo aprendido. Están pensados para ayudarte a consolidar los conceptos clave y prepararte para retos más avanzados.

Lo que aprendido aquí será una base sólida para todo lo que viene.

CAPÍTULO 4.- PROCESAMIENTO DE DATOS

4.1.- Limpieza de datos

4.1.1.- Tipos de Datos “Sucios”

4.1.2 Manejo de Datos Faltantes

4.1.3 Tratamiento de Datos Duplicados

4.1.4 Estandarización de Datos

4.1.5 Detección de Valores Atípicos

4.1.6 Tratamiento de Datos Desbalanceados



4.1.7 Renombrar Columnas

4.1.8 Codificación de Variables Categóricas

4.1.9 Registrar los Cambios

Por supuesto, Elena. Aquí tienes la transcripción completa del contenido de la imagen:

CAPÍTULO 5: ANÁLISIS EXPLORATORIO DE DATOS VISUAL

5.1 ANÁLISIS UNIVARIADO

- 5.1.1 Histogramas
- 5.1.2 Diagramas de Caja
- 5.1.3 Gráficos de conteo para datos categóricos
- 5.1.4 Estadísticas descriptivas junto con Visualizaciones
- 5.1.5 Gráfico de Densidad de Kernel
- 5.1.6 Diagrama de Violín
- 5.1.7 Sesgo y Curtosis de los Datos

5.2 ANÁLISIS BIVARIADO

- 5.2.1 Gráficos de Dispersión
- 5.2.2 Coeficiente de Correlación
- 5.2.3 Gráficos de Líneas
- 5.2.4 Mapas de Calor
- 5.2.5 Pairplots
- 5.2.6 Significancia Estadística en el Análisis Bivariado
- 5.2.7 Manejo de Variables Categóricas en el Análisis Bivariado
- 5.2.8 Aplicaciones del Análisis Bivariado en el Mundo Real

5.3 ANÁLISIS MULTIVARIADO

- 5.3.1 ¿Qué es el Análisis Multivariado?
- 5.3.2 Tipos de Análisis Multivariado
- 5.3.3 Ejemplo: Análisis de Componentes Principales (PCA)
- 5.3.4 Ejemplo: Análisis de Clústeres



- 5.3.5 Aplicaciones del Análisis Multivariado en el Mundo Real
- 5.3.6 Mapas de Calor para Matrices de Correlación
- 5.3.7 Ejemplo utilizando Análisis de Regresión Múltiple
- 5.3.8 Puntos de Precaución
- 5.3.9 Otras Técnicas de Reducción de Dimensionalidad

EJERCICIOS PRÁCTICOS CAPÍTULO 5

- Ejercicio 1: Análisis Univariado con Histogramas
- Ejercicio 2: Análisis Bivariado con Gráfico de Dispersión
- Ejercicio 3: Análisis Multivariado usando un Mapa de Calor

