



Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos (EDA) es una fase crítica en todo proyecto de ciencia de datos, donde se utilizan técnicas estadísticas y visuales para resumir las principales características de un conjunto de datos. Su objetivo principal es descubrir patrones, detectar anomalías, probar hipótesis y verificar supuestos, lo que permite una comprensión profunda de los datos antes de aplicar modelos complejos. Es la base para tomar decisiones informadas y asegurar la calidad y relevancia de cualquier análisis posterior.

CAPÍTULO 1: Importancia del EDA

El Análisis Exploratorio de Datos (EDA) no es solo un paso más en el proceso de ciencia de datos; es la brújula que guía todo el viaje. Realizar un EDA exhaustivo antes de cualquier análisis profundo o modelado es crucial por varias razones fundamentales que garantizan la solidez y la relevancia de tus conclusiones.



Identificación de Patrones y Tendencias

Permite descubrir relaciones ocultas, estructuras y comportamientos inesperados en los datos que podrían pasar desapercibidos en una inspección superficial.



Generación de Hipótesis y Preguntas

Facilita la formulación de preguntas y la creación de hipótesis de negocio o investigación que pueden ser validadas o refutadas en etapas posteriores del análisis.



Detección y Limpieza de Errores

Ayuda a identificar anomalías, valores atípicos, datos faltantes o inconsistencias, lo que es vital para asegurar la calidad y fiabilidad de tu conjunto de datos antes del modelado.



Guía para la Selección de Modelos

Proporciona información valiosa sobre las características de los datos, ayudando a seleccionar las técnicas estadísticas y los algoritmos de machine learning más apropiados para la tarea.

Beneficios Clave del EDA

El Análisis Exploratorio de Datos (EDA) no solo sienta las bases para un análisis riguroso, sino que también ofrece ventajas tangibles que impactan directamente en la toma de decisiones y la mitigación de riesgos en cualquier proyecto de datos.

Decisiones Más Sólidas

Una comprensión profunda de los datos permite tomar decisiones estratégicas basadas en evidencia, no en suposiciones.

Reducción de Riesgos

Identifica problemas potenciales como inconsistencias o sesgos, minimizando los errores en las fases posteriores del proyecto.

Optimización de Recursos

Al revelar la naturaleza de los datos, el EDA ayuda a elegir las técnicas y modelos más eficientes, ahorrando tiempo y esfuerzo.

Descubrimiento de Oportunidades

Patrones inesperados o correlaciones pueden señalar nuevas vías de negocio o áreas de mejora no consideradas inicialmente.



CAPÍTULO 2: Tipos de Datos

Exploramos la esencia de los datos, desde su estructura hasta cómo influyen en el análisis. Comprenderlos es el primer paso para desbloquear su verdadero potencial.

Datos Cualitativos vs. Cuantitativos

Datos Cualitativos

También conocidos como datos categóricos, describen características o atributos que no se pueden medir numéricamente, sino que se clasifican en categorías o grupos. Responden a preguntas como "¿qué tipo?" o "¿por qué?". Se usan para entender conceptos, opiniones o experiencias.

Ejemplos:

- Color de ojos (azul, marrón, verde)
- Género (masculino, femenino, no binario)
- Tipo de vehículo (coche, moto, bicicleta)
- Nacionalidad (española, mexicana, argentina)
- Opiniones de clientes (positivo, neutral, negativo)

Datos Cuantitativos

Son datos numéricos que se pueden medir o contar. Expresan cantidades y se utilizan para cálculos matemáticos y análisis estadísticos. Responden a preguntas como "¿cuánto?" o "¿cuántos?". Pueden ser discretos (valores enteros) o continuos (cualquier valor dentro de un rango).

Ejemplos:

- Edad (25, 30, 45)
- Altura (1.75 m, 1.60 m)
- Temperatura (20°C, 35°C)
- Ingresos anuales (€30,000, €50,000)
- Número de ventas (100 unidades, 250 unidades)

Tipos de Datos Cuantitativos: Discretos y Continuos

Datos Cuantitativos Discretos

Los datos discretos son valores numéricos que solo pueden tomar números enteros y específicos. Son el resultado de un conteo y no pueden dividirse en fracciones o decimales significativos. Se caracterizan por tener un número finito o contable de valores posibles.

Ejemplos:

- Número de estudiantes en un aula (no puedes tener 2.5 estudiantes)
- Cantidad de vehículos vendidos por un concesionario en un mes
- Número de errores en una línea de código
- Puntuación en un test de selección múltiple (si las preguntas valen 1 punto)

Datos Cuantitativos Continuos

Los datos continuos son valores numéricos que pueden tomar cualquier valor dentro de un rango específico, incluyendo fracciones, decimales y números irracionales. Son el resultado de mediciones y su precisión está limitada únicamente por el instrumento de medida utilizado.

Ejemplos:

- Altura de un árbol (puede ser 10.5 metros, 10.55 metros, etc.)
- Temperatura ambiente (23.4°C, 23.45°C, etc.)
- Peso de un paquete (2.15 kg, 2.153 kg, etc.)
- Tiempo transcurrido en una carrera (10.23 segundos, 10.235 segundos)

Tipos de Datos Cualitativos: Nominales y Ordinales

Dentro de los datos cualitativos, es fundamental distinguir entre aquellos que solo sirven para categorizar y los que además implican un orden o jerarquía. Esta distinción afecta directamente los tipos de análisis estadísticos que se pueden aplicar.

Datos Cualitativos Nominales

Son datos que representan categorías sin ningún orden inherente o jerarquía. Las categorías son mutuamente excluyentes y no se puede establecer una relación de "mayor que" o "menor que" entre ellas. Su principal función es la de clasificar y diferenciar.

Ejemplos:

- Estado civil (soltero, casado, divorciado, viudo)
- Tipo de sangre (A, B, AB, O)
- País de origen (España, México, Argentina, Colombia)
- Marca de coche (Ford, Toyota, BMW, Tesla)
- Género del producto (electrónica, ropa, alimentos)

Datos Cualitativos Ordinales

Estos datos también representan categorías, pero a diferencia de los nominales, sí tienen un orden o secuencia natural. Aunque se pueden clasificar, la distancia entre las categorías no es necesariamente uniforme o cuantificable. Se utilizan para indicar grados o niveles.

Ejemplos:

- Nivel de educación (primaria, secundaria, universitaria, posgrado)
- Grado de satisfacción (muy insatisfecho, insatisfecho, neutral, satisfecho, muy satisfecho)
- Clasificación de medallas (oro, plata, bronce)
- Talla de ropa (pequeña, mediana, grande, extra grande)
- Nivel socioeconómico (bajo, medio, alto)



CAPÍTULO 3: Estadística Descriptiva

Este capítulo es su puerta de entrada a la estadística descriptiva, donde aprenderemos a resumir, organizar y presentar datos de manera significativa. Prepárese para transformar conjuntos de datos complejos en información clara y concisa.

Medidas de Tendencia Central

Las medidas de tendencia central son estadísticas que resumen un conjunto de datos identificando el punto central alrededor del cual se agrupan los datos. Son esenciales para una comprensión inicial de la distribución de nuestros valores.

Media (Promedio)

La suma de todos los valores dividida por el número total de valores. Es sensible a valores extremos.

Uso: Datos cuantitativos sin valores atípicos significativos.

Mediana

El valor central en un conjunto de datos ordenado. Divide los datos en dos mitades iguales.

Uso: Datos cuantitativos con valores atípicos o distribuciones sesgadas.

Moda

El valor o valores que aparecen con mayor frecuencia en un conjunto de datos.

Uso: Datos cualitativos o cuantitativos para identificar valores populares/comunes.

Medidas de Dispersión

Las medidas de dispersión complementan a las de tendencia central, indicando el grado en que los datos se extienden o varían alrededor de su centro. Son cruciales para entender la consistencia y fiabilidad de los datos.

Rango

Es la diferencia entre el valor máximo y el valor mínimo en un conjunto de datos. Ofrece una idea rápida de la amplitud total de la distribución.

Uso: Para una estimación rápida y sencilla de la variabilidad de los datos, especialmente en conjuntos pequeños.

Varianza

Mide la dispersión promedio de los datos con respecto a la media. Se calcula como el promedio de los cuadrados de las diferencias de cada dato con la media.

Uso: Para comprender cuán extendidos están los datos, penalizando más las desviaciones grandes.

Desviación Estándar

Es la raíz cuadrada de la varianza. Se expresa en las mismas unidades que los datos originales, lo que la hace más fácil de interpretar que la varianza.


Uso: Es la medida de dispersión más común, útil para evaluar la consistencia y homogeneidad de los datos.

Cuartiles y Percentiles

Los cuartiles y percentiles son medidas de posición que nos permiten entender cómo se distribuyen los datos y dónde se ubica un valor específico dentro de un conjunto ordenado. Dividen el conjunto de datos en segmentos iguales para un análisis más detallado.

Los **Cuartiles** dividen el conjunto de datos ordenado en cuatro partes iguales:

- **Q1 (Primer Cuartil):** El 25% de los datos es menor o igual que este valor.
- **Q2 (Segundo Cuartil):** Es la Mediana; el 50% de los datos es menor o igual.
- **Q3 (Tercer Cuartil):** El 75% de los datos es menor o igual que este valor.



Los **Percentiles** generalizan esta idea, dividiendo los datos en 100 partes iguales. Por ejemplo, el Percentil 90 indica que el 90% de los datos está por debajo de ese valor.

CAPÍTULO 4:

Procesamiento de Datos

Este capítulo nos guiará a través de los pasos esenciales para transformar datos crudos en información lista para el análisis. Aprenderemos técnicas de limpieza, validación y preparación para asegurar la calidad y fiabilidad de nuestros conjuntos de datos.



Problemas Comunes en la Calidad de los Datos

Antes de sumergirnos en el análisis, es crucial entender los problemas que a menudo encontramos en los datos crudos. Identificarlos y abordarlos es el primer paso para garantizar resultados fiables y precisos.



Valores Faltantes

Son datos no registrados o ausentes en una o más variables. Pueden surgir por errores en la recolección, fallos del sistema o falta de respuesta. Su presencia puede sesgar los análisis, reducir el tamaño efectivo de la muestra y complicar la construcción de modelos, haciendo que las conclusiones sean menos representativas.



Registros Duplicados

Se refieren a la presencia de entradas idénticas o casi idénticas en el conjunto de datos. Pueden deberse a errores de entrada, fusiones de bases de datos o fallos en los sistemas de registro. Los duplicados inflan artificialmente los recuentos, distorsionan las estadísticas descriptivas y pueden llevar a un uso ineficiente de recursos si no se identifican y eliminan.



Valores Atípicos (Outliers)

Son observaciones que se desvían significativamente de la mayoría de los otros datos en un conjunto. Pueden ser el resultado de errores de medición, errores de entrada o simplemente representar eventos raros pero legítimos. Los outliers pueden influir desproporcionadamente en medidas como la media y la desviación estándar, afectando la validez de los modelos y las inferencias estadísticas.

Técnicas de Limpieza de Datos

La limpieza de datos es un paso crítico para asegurar la calidad de la información. Aquí exploramos las estrategias clave para abordar los problemas más comunes y preparar sus datos para un análisis confiable.



Manejo de Valores Faltantes

Decida entre **eliminar** las filas o columnas incompletas, o **imputar** los valores faltantes utilizando métodos como la media, mediana, moda, o técnicas más avanzadas de regresión. La elección depende del volumen de datos y la naturaleza de la información.



Eliminación de Registros Duplicados

Identifique y **remueva** entradas idénticas o casi idénticas en su conjunto de datos. Este proceso asegura que cada observación sea única, evitando la sobreestimación de frecuencias y el sesgo en los análisis estadísticos posteriores.



Tratamiento de Valores Atípicos

Tras identificar los outliers (por ejemplo, con métodos como el rango intercuartílico o Z-scores), puede optar por **eliminarlos**, **transformar** los datos para reducir su impacto (ej. logaritmos), o **imputar** un valor más representativo basado en límites estadísticos.

CAPÍTULO 5: Análisis Exploratorio de Datos Visual

En este capítulo, transformaremos números y tablas en imágenes poderosas. Descubriremos cómo las visualizaciones nos permiten identificar patrones, tendencias y anomalías de manera intuitiva, facilitando la extracción de conocimientos valiosos de nuestros datos.



Tipos de Gráficos para EDA

El Análisis Exploratorio de Datos (EDA) se potencia enormemente con visualizaciones. Los gráficos nos permiten descubrir patrones, anomalías y relaciones en nuestros datos de forma intuitiva. Aquí te presentamos los tipos más fundamentales para iniciar tu exploración.

Histogramas

Muestran la distribución de frecuencia de una sola variable numérica. Dividen los datos en "contenedores" y cuentan cuántas observaciones caen en cada uno, permitiendo visualizar la forma de la distribución, la dispersión y la presencia de sesgos o picos.

Uso: Para entender la forma subyacente de la distribución de los datos, identificar si son simétricos, sesgados, unimodales o multimodales.

Boxplots (Diagramas de Caja)

Proporcionan una representación visual de la distribución de un conjunto de datos a través de cinco estadísticas clave: el mínimo, el primer cuartil (Q1), la mediana (Q2), el tercer cuartil (Q3) y el máximo. También identifican valores atípicos (outliers).

Uso: Ideales para comparar la distribución de una variable numérica entre diferentes categorías o grupos, y para detectar rápidamente la presencia de outliers.

Gráficos de Dispersión (Scatter Plots)

Representan la relación entre dos variables numéricas. Cada punto en el gráfico corresponde a un par de valores de las dos variables. Esto nos permite observar patrones, tendencias, correlaciones o agrupaciones entre las variables.

Uso: Fundamentales para investigar la relación entre dos variables, como la correlación lineal o no lineal, e identificar posibles clusters de datos o anomalías.

Gráficos para Datos Categóricos

Para visualizar la distribución de datos categóricos, es fundamental elegir el gráfico adecuado. Los gráficos de barras y los circulares son herramientas clave, cada uno con sus fortalezas específicas.

Gráficos de Barras

Ideales para comparar la frecuencia o proporción de múltiples categorías. Permiten una lectura clara incluso con un número elevado de categorías, mostrando las diferencias de tamaño de forma efectiva.

Gráficos Circulares (Pie Charts)

Excelentes para representar partes de un todo, mostrando cómo las categorías individuales contribuyen al total. Se recomiendan para un número pequeño de categorías (2 a 5) donde la suma de todas las partes es el 100%.

Matrices de Correlación y Heatmaps


Estas herramientas visuales son esenciales en el Análisis Exploratorio de Datos (EDA) para desvelar rápidamente las relaciones entre múltiples variables, ofreciendo una comprensión profunda de cómo se comportan los datos en conjunto.

Matrices de Correlación

Una matriz de correlación es una tabla donde cada celda muestra el coeficiente de correlación entre dos variables. Estos valores, que oscilan entre -1 y 1, indican la fuerza y dirección de su relación: positivo (ambas aumentan), negativo (una aumenta y la otra disminuye) o nulo (sin relación lineal).

Heatmaps

Los heatmaps transforman visualmente estas matrices. Utilizan escalas de color para representar la magnitud de los coeficientes de correlación, permitiendo identificar de un vistazo las relaciones más fuertes (colores intensos) y débiles (colores suaves) entre pares de variables. Son excelentes para detectar redundancia de variables y oportunidades de ingeniería de características.



EJERCICIOS PRÁCTICOS: Análisis Visual

Ponga en práctica lo aprendido con estos ejercicios diseñados para fortalecer sus habilidades en la visualización exploratoria de datos. Utilice cualquier conjunto de datos que le interese para aplicar estas técnicas.




Exploración de Distribuciones

Seleccione una variable numérica de su dataset. Cree un **histograma** para visualizar su distribución y un **boxplot** para identificar la mediana, cuartiles y posibles valores atípicos. Describa la forma, el centro y la dispersión.



Análisis de Relaciones Bivariadas

Elija dos variables numéricas y genere un **gráfico de dispersión**. Observe si existe una correlación (positiva, negativa, nula) y su fuerza. ¿Detecta algún patrón particular o agrupaciones de datos que merezcan más investigación?



Visualización de Datos Categóricos

Tome una variable categórica de su dataset. Construya un **gráfico de barras** para mostrar la frecuencia de cada categoría y un **gráfico circular** para representar las proporciones. Compare cuál es más efectivo según el número de categorías.

Conclusiones Clave del Análisis Exploratorio de Datos

El Análisis Exploratorio de Datos (EDA) es una fase indispensable en cualquier proyecto de datos. Hemos cubierto las herramientas y técnicas esenciales para desvelar la historia que sus datos quieren contar.



Entender la Estructura

El EDA nos permite comprender la distribución, patrones y la naturaleza de nuestras variables antes de cualquier modelado.



Asegurar la Calidad

Identificar y tratar valores ausentes o atípicos es crucial para la fiabilidad de cualquier análisis posterior.



Visualización Esencial

Los gráficos son la ventana a nuestros datos, revelando de forma intuitiva distribuciones, relaciones y anomalías.



Relaciones Profundas

Herramientas como las matrices de correlación nos ayudan a entender cómo las variables interactúan entre sí.