


Dominando la Regresión Lineal

De la teoría a la implementación práctica en Python



¿Podemos predecir el futuro con datos?

Un modelo predictivo es una herramienta matemática que utiliza datos históricos para predecir resultados futuros. A través de técnicas de aprendizaje automático y análisis de patrones, estos modelos identifican tendencias y relaciones en grandes volúmenes de datos.

Los modelos predictivos son fundamentales en la toma de decisiones informadas en prácticamente todos los sectores.

Aplicaciones Clave:



Negocios: Optimizar procesos.



Finanzas: Anticipar comportamientos del mercado.



Marketing: Prever la demanda de un producto.



Medicina: Estimar la progresión de una enfermedad.

El Ecosistema de los Modelos Predictivos

Modelos de Regresión

Uso:

Predecir valores continuos (ej. precio, temperatura).

Ejemplos:

Regresión Lineal, Regresión Logística.

Modelos de Clasificación

Uso:

Predecir la pertenencia a una clase (ej. sí/no, fraude/no fraude).

Ejemplos:

Árboles de Decisión, SVM.

Redes Neuronales

Uso:

Modelar relaciones extremadamente complejas, imitando el cerebro humano.

Ejemplos:

Deep Learning.

Modelos de Clustering

Uso:

Separar datos en categorías basadas en características similares.

Ejemplos:

K-means, DBSCAN.

¿Qué es la Regresión Lineal y por qué es fundamental?

Definición: Es una técnica estadística que permite predecir el comportamiento de una variable numérica (dependiente) a partir de una o más variables (independientes), mediante el ajuste de una ecuación lineal.

Su Poder: No solo predice, sino que **cuantifica el impacto** de cada variable. Responde a preguntas como:

- *¿Cuánto aumenta el precio de una vivienda por cada metro cuadrado adicional?*
- *¿Qué porcentaje de las ventas depende del presupuesto en marketing?*

Tipos Principales:

- **Simple:** Una variable independiente (ej. horas de estudio -> nota del examen).
- **Múltiple:** Dos o más variables independientes (ej. área + habitaciones -> precio de la casa).



La Ecuación que Dibuja el Futuro

La base de la regresión lineal es la fórmula de la recta. El objetivo del modelo es encontrar los valores de los coeficientes (β) que minimicen el error entre las predicciones y los valores reales, usando métodos como el de Mínimos Cuadrados.

The diagram shows the linear equation $y=mx+b$ with four dashed arrows pointing from labels below to the corresponding parts of the equation:

- An orange arrow points from "Variable dependiente" to the y .
- A blue arrow points from "Pendiente" to the m .
- A green arrow points from "Variable independiente" to the x .
- A purple arrow points from "Punto de corte eje Y (cuando $x=0$)" to the b .

****Regresión Simple**:**

$$Y = \beta_1 X + \beta_0 + \varepsilon$$

****Regresión Múltiple**:**

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

****Componentes Clave**:**

- **β_0 (Intercepto)**: Valor de Y cuando todas las X son cero.
- **β_j (Coeficientes)**: El efecto de cada variable X sobre Y .
- **ε (Error)**: La diferencia entre el valor predicho y el real.

Primer Caso Práctico: Regresión Lineal Simple

El Reto: "¿Podemos predecir los ingresos anuales de una persona basándonos únicamente en sus años de experiencia laboral?"


💰 **Variable Dependiente (Y):** Ingresos

👜 **Variable Independiente (X):** Experiencia



La Herramienta

Usaremos Python con las librerías `pandas`, `matplotlib` y `scikit-learn`.



El Proceso

Seguiremos 4 pasos clave para construir y evaluar nuestro modelo.

1. Carga y Visualización

2. Entrenamiento del Modelo

3. Interpretación de Resultados

4. Realización de Predicciones



Paso 1: Carga y Visualización de Datos

Leemos el fichero `.csv` y creamos un gráfico de dispersión para observar la relación entre experiencia e ingresos.

```
# Leemos los datos del fichero
datos = pd.read_csv("regresion_lineal_simple.csv")

# Mostramos el gráfico de dispersión
plt.ylabel("Ingresos")
plt.xlabel("Experiencia")
plt.scatter(datos["Experiencia"], datos["Ingresos"], color="gold")
plt.show()
```

	Experiencia	Ingresos
0	7	38991.994707
1	20	54141.855824
2	29	63964.067099
3	15	53443.128632
4	11	45427.660622
...	...	...



Paso 2: Entrenamiento del Modelo


Preparamos los datos en los formatos correctos (X en 2D, Y en 1D) y utilizamos la función `fit()` de `scikit-learn` para ajustar el modelo. Esta función calcula los coeficientes (β_0 , β_1) que mejor se adaptan a los datos.

Código Esencial

```
# Preparamos X (2D) e Y (1D)
x = datos["Experiencia"].values.reshape((-1, 1))
y = datos["Ingresos"].values

# Calculamos nuestra regresión lineal
regresion = linear_model.LinearRegression()
modelo = regresion.fit(x, y)
```

Resultado Visual



El modelo ha encontrado la línea óptima que minimiza la distancia a todos los puntos.

Paso 3: Interpretación de los Resultados

Coeficientes del Modelo in Source Sans Pro Regular

Intercepto (β_0): 24,587.43. Una persona con 0 años de experiencia ganaría aproximadamente **€24,587**.

Pendiente (β_1): 1,531.12. Por cada año adicional de experiencia, los ingresos aumentan en promedio **€1,531**.

Bondad del Ajuste (R^2) in Source Sans Pro Regular


R^2 : 0.89

Esto significa que el **89% de la variación** en los ingresos es explicada por la experiencia. Un **ajuste muy bueno**.

Análisis de Residuos in Source Sans Pro Regular

Concepto: Los residuos son la diferencia entre los valores reales y los predichos. Un buen modelo no debe tener errores sistemáticos.

Interpretación: Los errores se distribuyen cerca de 0, lo que confirma que el modelo es razonablemente bueno.



Paso 4: Realización de Predicciones

Con el modelo ya entrenado, podemos predecir los ingresos para nuevos valores de experiencia.

¿Cuánto ganará una persona con 3.5, 7, 13 o 31 años de experiencia?


Código Esencial

```
# Predecimos el salario para nuevos valores
entrada = [[3.5], [7], [13], [31]]
prediccion = modelo.predict(entrada)
print(prediccion)
```

Resultado

Predicciones:
[29946.34275492
35305.25480507
44491.96117675
72052.08029179]

Interpretación:
Para 13 años de experiencia, el modelo predice un salario de €44,491.96.



Ampliando el Arsenal: Regresión Múltiple


El Nuevo Reto

Predecir el precio de una vivienda utilizando múltiples factores.

- **Variable Dependiente (Y):** Precio
- **Variables Independientes (X):**
 1. "Área (en m²)"
 2. "Distancia al centro (en km)"

El Cambio Clave


En lugar de ajustar una línea en 2D, ahora ajustaremos un **plano** en un espacio 3D.



De una Línea a un Plano: Entrenando e Interpretando

Acción

Entrenamos el modelo con ambas variables predictoras. El resultado es un plano de regresión que minimiza el error con respecto a todos los puntos de datos.



Interpretación de Resultados

Coeficientes

Coeficientes: [2886.47420145 -22328.6410586]

- **Área (€2,886.47):** Por cada m² adicional, el precio aumenta en €2,886, manteniendo la distancia constante.
- **Distancia (-€22,328.64):** Por cada km más lejos del centro, el precio disminuye en €22,328, manteniendo el área constante.

R² (Bondad de Ajuste)

R²: 0.93

- **R²: 0.93.** El modelo explica el **93% de la variabilidad** en los precios de las viviendas. Un ajuste excelente.

Poniendo a Prueba el Modelo Múltiple



Predicción Específica

****Pregunta**:** ¿Cuánto costará una vivienda de 130m² situada a 10km del centro?

```
prediccion = regresion.predict([[130, 10]])
```

****Resultado**:** [€478,269.21]

Análisis de Residuos



****Análisis**:** A pesar del R^2 del 93%, el histograma muestra residuos más dispersos y con picos. Esto sugiere que aunque el modelo es muy bueno en general, comete errores más grandes para ciertos puntos. No podemos fiarnos ciegamente de todas las predicciones.

Las Reglas del Juego: Supuestos para un Modelo Fiable

Para que un modelo de regresión lineal sea válido y sus inferencias fiables, deben cumplirse ciertos supuestos básicos. Conocerlos es clave para un análisis riguroso.



1. Linealidad: La relación entre las variables predictoras y la dependiente debe ser lineal.



2. Independencia: Las observaciones deben ser independientes entre sí (el valor de una no debe influir en otra).



3. Homocedasticidad: Los errores deben tener una varianza constante a lo largo de todas las predicciones.



4. Normalidad de los Residuos: Los residuos deben seguir una distribución normal (la forma de campana de Gauss).

Usted Ahora Tiene el Poder de Predecir

- ✓ Hemos situado la **Regresión Lineal** dentro del ecosistema de modelos predictivos.
- ✓ Hemos desmitificado su **base matemática**, entendiendo la ecuación de la recta.
- ✓ Hemos implementado en Python un modelo de **Regresión Simple** para predecir ingresos.
- ✓ Hemos escalado a una **Regresión Múltiple** para valorar viviendas, aprendiendo a interpretar el impacto de múltiples factores.

La regresión lineal es más que una fórmula; es una herramienta poderosa para cuantificar relaciones y tomar decisiones basadas en evidencia. Ahora usted puede aplicarla para encontrar las historias ocultas en sus propios datos.