

PRÁCTICA 4.1. El Análisis de Datos y el Misterio de los Aerostatos

Contexto de la Investigación

Has sido contratado como analista forense de datos para investigar una serie de avistamientos de objetos voladores no identificados (aerostatos). Tu misión es limpiar los datos, identificar patrones ocultos y construir un modelo capaz de predecir la capacidad operativa de estos objetos frente a condiciones climáticas adversas.

Objetivos de la práctica

- **Realizar una carga y exploración estructural completa.**
(Teoría: *EDA estructural, tipos de datos, dimensiones, head/tail de DataFrames*).
- **Aplicar técnicas de limpieza e imputación estadística robusta.**
(Teoría: *Calidad de datos, valores perdidos, imputación con media/mediana/moda*).
- **Detectar y analizar valores atípicos (outliers) que distorsionan la realidad.**
(Teoría: *Outliers, IQR, boxplots, impacto en medidas de tendencia central y dispersión*).
- **Realizar ingeniería de características para evaluar el peligro potencial.**
(Teoría: *Ingeniería de variables, creación de nuevas características, transformaciones*).
- **Validar la relación entre variables mediante matrices de correlación evolutivas.**
(Teoría: *Correlación, matrices de correlación, heatmaps, análisis bivariado/multivariante*).
- **Construir y validar un modelo de Regresión Lineal.**
(Teoría: *Regresión lineal simple, ecuación de la recta, R^2 , análisis de residuos*).

Fase 1: Observar y Limpiar el Escenario (EDA Estructural)

- **Carga y Magnitud:** Importa el archivo `avistamientos_aerostatos.csv` (basado en los datos de `Avistamiento.pdf`). Muestra las dimensiones del dataset y realiza una inspección visual de las primeras y últimas 5 filas.
(Teoría: *Lectura de datos con pandas, shape, head(), tail(), tipos de variables*).
- **Forense de Datos:** Identifica y elimina registros duplicados.
(Teoría: *Calidad de datos, duplicados, drop_duplicates()*).
- **Testigos Silenciosos:** Detecta valores nulos. Aplica una imputación estadística:
 - Rellena la `Altitud_km` con la mediana (para evitar el sesgo de valores extremos).
 - Rellena la `Tecnologia_Detectada` con la moda.
(Teoría: *Valores faltantes, isnull(), imputación con mediana y moda, robustez frente a outliers*).

Fase 2: Perfilado y Detección de Anomalías

- **Resumen Estadístico:** Genera el perfil cuantitativo con `.describe()`.
(Teoría: *Estadísticos descriptivos univariantes: media, mediana, desviación típica, cuartiles*).
- **Análisis de Distribución:** Calcula la asimetría (skew) y la curtosis de la variable `Altitud_km`. Explica por qué un valor de curtosis muy elevado (ej. > 170) indica la presencia de outliers severos.
(Teoría: *Forma de la distribución, asimetría, curtosis, colas pesadas, relación con outliers*).
- **Caza de Outliers:** Utiliza el método del Rango Intercuartílico (IQR) para identificar registros "imposibles" en la altitud y visualízalos mediante un Boxplot.
(Teoría: *IQR, regla de $1.5 \cdot IQR$, detección de outliers, boxplot como herramienta gráfica*).

Fase 3: Identificar Cómplices (Análisis de Relaciones)

- **Matriz de Correlación Inicial:** Genera un mapa de calor (heatmap) con las variables numéricas originales para identificar qué factores varían juntos (ej. Viento vs. Maniobra).
(Teoría: *Coeficiente de correlación de Pearson, matrices de correlación, visualización con heatmap*).
- **Ingeniería de Características:** Crea un nuevo indicador llamado `Indice_Riesgo` combinando la duración del vuelo y la cercanía a bases militares mediante la fórmula:
$$\text{Indice_Riesgo} = \frac{\text{Duracion_Vuelo_h}}{\text{Cercania_Base_Militar_km} + 1}$$

(Teoría: *Ingeniería de características, construcción de índices compuestos, transformaciones no lineales*).
- **Clasificación Estratégica:** Utiliza `pd.cut()` para crear la variable categórica `Nivel_Alerta` (Bajo, Moderado, Crítico) basada en el índice anterior.
(Teoría: *Discretización de variables continuas, creación de categorías, binning con `pd.cut()`*).
- **Re-planteamiento de la Matriz (Paso Crítico):** Vuelve a generar la matriz de correlación incluyendo el nuevo `Indice_Riesgo`. Analiza si esta nueva variable tiene mayor relación con otras que las variables originales por separado.
(Teoría: *Comparación de correlaciones, evaluación de utilidad de nuevas variables, análisis multivariante*).

Fase 4: Modelado Predictivo

- **Regresión Lineal Simple:** Entrena un modelo para predecir el `Indice_Maniobra` (Variable Y) basándote en la `Velocidad_Viento_kmh` (Variable X).
(Teoría: *Regresión lineal simple, variable dependiente e independiente, ajuste del modelo*).
- **Interpretación de Resultados:**
 - Muestra la ecuación de la recta ($Y = mX + b$).

- Interpreta la Bondad de Ajuste (R^2). Un valor cercano a 0.82 indica una alta fiabilidad. (Teoría: *Pendiente e intercepto, interpretación de coeficientes, R^2 como proporción de varianza explicada*).
- **Validación del Modelo:** Genera un histograma de residuos. Explica si el modelo es fiable basándote en si los residuos siguen una distribución normal centrada en cero. (Teoría: *Análisis de residuos, supuestos de la regresión lineal, normalidad y media cero de los errores*).
- **Plantea una nueva recta de regresión en la que una de las variables sea el Índice_Riesgo. Explica el razonamiento para elegir la segunda variable y todos los pasos que realizas, así como la bondad del ajuste. Utiliza las rectas de regresión para realizar un par de predicciones. Argumenta tu respuesta.** (Teoría: *Selección de variables, comparación de modelos, interpretación de regresión, uso del modelo para predicción, evaluación con R^2 y residuos*).

Obligatorio en la entrega

- **Cuaderno de Jupyter (.ipynb):** Con celdas de Markdown que expliquen cada hallazgo "detectivesco". (Teoría: *Documentación de análisis, narrativa de EDA, buenas prácticas en ciencia de datos*).
- **Visualizaciones:** Mapa de calor (antes y después), Boxplot de outliers y Recta de regresión sobre nube de puntos. (Teoría: *Visualización de datos: heatmap, boxplot, scatter + línea de regresión*).
- **Conclusión:** Un breve informe justificando si el viento es el único "culpable" de la pérdida de maniobra o si existen "cómplices" ocultos. (Teoría: *Interpretación de resultados, síntesis de EDA + correlación + regresión, discusión de variables relevantes*).