

PRÁCTICA 4.2 . ANÁLISIS DE DATOS

Genera un documento realizando un análisis de datos a un dataset sobre el coste de seguros de coches en función de varias variables. Para ello realiza las siguientes tareas y adjunta en la entrega el archivo de código en Python con la solución y aportando conclusiones en forma de comentarios.

Columnas del dataset **seguro.csv**

- Edad conductor
- Experiencia conductor: Años de carnet de la persona asegurada.
- Accidentes previos
- Kilometraje anual (x1000 km): Distancia en kilómetros que conduce el asegurado al año. Se multiplican los valores por mil para obtener los km reales.
- Año fabricación coche
- Edad coche
- Seguro Premium (€): Coste del seguro al año.
- Sexo

DATAFRAMES (1.5 punto)

1. Muestra cuántas columnas y filas existen en el dataset.
2. Guarda los nombres de las columnas en una lista.
3. Comprueba que no existe ningún null/nan en el dataset. En caso de existir, elimina las filas que contengan valores nulos.
4. Añade una columna “**Accidentado**” que contenga valores “**Si**” o “**No**” según si la persona ha sufrido algún accidente.
5. Crea el dataframe **df_virtuosos** que contenga las filas donde **Accidentes previos = 0**, excluyendo la columna de **Accidentes Previos** y la de **Accidentado**.
6. Añade a **df_virtuosos** una columna que sea la relación coste/experiencia. En las filas donde experiencia = 0, el coste debe ser el mismo que si llevase 1 año de carnet.
7. Muestra el resumen estadístico del DataFrame original

CONSULTAS (3 puntos)

Realiza las consultas siguientes, de manera que se muestre el resultado, a partir de los datos originales.

1. ¿Cuál es el porcentaje de accidentados y no accidentados en el dataset?
2. ¿Cuál es la experiencia media por sexo y la total? Calcula la experiencia media de conducción para hombres y mujeres por separado, así como el promedio general.
3. ¿Cuál es la media y la desviación estándar del coste del seguro en función de la experiencia? Osea, media del precio con 1 año de carnet, 2 años, etc...¿Cuál de estas medias es mayor y cuál menor?
4. ¿Cómo se distribuyen los no accidentados por grupos de antigüedad del coche? (Edad en rangos: 0-9, 10-19, etc.)
5. ¿Cuál es la media de experiencia conduciendo en mujeres aseguradas con coches fabricados después del 2015?
6. ¿Qué porcentaje de conductores con más de 30 años son hombres?

GRÁFICOS (2 puntos)

Genera los gráficos que se piden a continuación de la manera más profesional posible (colores, legenda, nombres de ejes, etc).

1. Haz un gráfico de tartas con la proporción en el dataset entre accidentados y no accidentados.
2. Gráfico de tartas con la proporción según número de accidentes agrupándolo por categorías (0, 1a3, 3a4, 5+).
3. Haz un histograma con el coste del seguro, que muestre la densidad de la distribución de probabilidad, con 10 barras. Comenta lo que ves.
4. Haz una nube de puntos con la edad en el eje x y los costes en el eje y, separando en 2 colores diferentes hombres/mujeres. Comenta lo que ves.

CONVERSIÓN DE VARIABLES (0.5 puntos)

Para realizar regresión lineal necesitamos que todas las variables sean numéricas. Haz una copia del dataset llamado **"data_num"** y convierte las variables categóricas en numéricas:

	Sí	No
Accidentados	1	0
	Hombre	Mujer
Sexo	1	0

En el tema 2 vimos herramientas para realizar este tipo de conversiones (por ejemplo el empleo de `map()` podría ser una opción)

REGRESIÓN LINEAL (3 puntos)

1. Calcula la correlación entre variables. ¿Cuál es la mayor correlación entre variables? ¿Cuál es la menor?
2. Genera una nube de puntos con Accidentes Previos en el eje X y el precio del seguro en el eje Y.
Calcula la recta de regresión entre ambas variables y pínchala en el gráfico. Comenta los coeficientes obtenidos y lo que interpretas.
Usa el modelo para predecir cuánto le costará el seguro a alguien con 6 accidentes previos.
3. Entrena un modelo de regresión lineal múltiple. Vamos a predecir el precio del seguro según la edad del conductor, la edad del coche y el kilometraje anual. Quiero que lo hagas con división de datos:
 - a. El 85% de los datos van a entrenamiento
 - b. El 15% de los datos van a test.Evalúa el modelo de regresión múltiple que has obtenido.