




Transformación y Limpieza de Datos: Distribución de Renta en Hogares

Un flujo de trabajo integral de ETL con Python y Pandas para optimizar datasets demográficos (2015–2023).

Resumen Ejecutivo del Proyecto



El Objetivo

Limpiar y estructurar el archivo "dist_renta_hogares.csv", un dataset con 78,732 registros sobre la renta por unidad de consumo en España.



La Estrategia

Utilizar el ecosistema de Python (**Pandas/NumPy**) para normalizar jerarquías geográficas, imputar valores faltantes y optimizar el uso de memoria.



El Resultado

Un dataset normalizado, con tipos de datos corregidos (category, datetime, float) y nuevas variables segmentadas, listo para modelos de Machine Learning.

Perfil del Dataset Original

El archivo fuente 'dist_renta_hogares.csv' contiene información demográfica rica pero técnicamente ruidosa.

- Volumen: 78,732
filas × 8 columnas
- Jerarquía:
Municipio → Distrito
→ Sección
- Dimensiones:
Sexo, Nacionalidad,
Periodo (2015-2023)

Municipio	Distrito	Sección	Sexo	Nacionalidad	Periodo	Total	Distribución
Ponto	1		Female	Cola	2015	.)	
Ponta	2		Male	Cola	2015	26	
Ponta	3		Female	Cola	2015		
Puena	4		Male	Cola	2015	109	
...	...	...	...	...	...	...	...
...	...	...	...	...	...	...	...

Contaminación
con caracteres
de texto (.)

Valores Nulos
(NaN) presentes

Diagnóstico Inicial y Detección de Anomalías

```
import pandas as pd
data = pd.read_csv('./dist_renta_hogares.csv', delimiter=';')
display(data.head())
```

Municipios	Distritos	Sección	Sexo	Nacionalidad	Periodo	Total	Distribución
Madrid	Centro	1.0	Female	Spanish	2020	28563.0	0.45
Barcelona		2.0	Male	Spanish	2020	30120.5	0.48
Valencia	Latina	3.0	Female	Spanish	2020	.	0.50
Sevilla		4.0	Male	Spanish	2020	31200.0	0.47
Zaragoza	Usera	5.0	Female	Spanish	2020	29150.0	0.49

Valores Nulos

La inspección revela que la jerarquía geográfica está incompleta y la columna numérica crítica ('Total') está contaminada con texto.

Datos Sucios (String)


Estrategia de Imputación de Valores Nulos

Aplicando lógica de negocio para resolver vacíos de información.



Limpieza Avanzada: Recuperando Datos Numéricos

La columna 'Total' contiene caracteres '.' que impiden el análisis matemático.



```
# Reemplazar puntos literales por 0  
usando Regex  
data['Total'] =  
    data['Total'].replace('^\\.$', 0,  
regex=True)  
  
# Forzar la conversión a tipo numérico  
data['Total'] =  
    pd.to_numeric(data['Total'],  
errors='coerce')
```


Imputación Estadística en la Variable Objetivo


Una vez convertida la columna 'Total' a formato numérico, procedemos a eliminar los huecos estadísticos restantes.



Este paso asegura la integridad del dataset, permitiendo cálculos agregados sin perder registros valiosos.

Optimización de Memoria y Tipos de Datos


Conversión de columnas de texto (object) a 'category' para reducir el uso de RAM.



Esta optimización es crítica cuando se escala el análisis a millones de registros.

Ingeniería de Características: Extracción Geoespacial


Objetivo: Aislar el Código Postal implícito dentro de la columna "Municipios".



```
data['Cod_Postal'] = data['Municipios'].astype(str).str[:5]
```

Permite un ordenamiento descendente por código postal y habilita futuros cruces con mapas de calor.

Normalización Temporal y Ordenamiento



Segmentación de Negocio: Categorización de Renta

Convierte una variable continua abstracta en segmentos accionables.



0% – 33.33%



33.33% – 66.66%



66.66% – 100%

```
data['Porcentaje'] = pd.cut(data.Total,  
                             bins=[0, 33.33, 66.66, 100],  
                             labels=['Bajo', 'Medio', 'Alto'],  
                             right=False)
```


Auditoría Final del Dataset Limpio

Column Name	Data Type		Sin valores nulos en columnas críticas.
Municipios	object		Tipos de datos optimizados.
Periodo	datetime64[ns]		Nuevas columnas de valor añadido (Cod_Postal , Porcentaje).
Total	float64		
Cod_Postal	object		
Porcentaje	category		

El caos inicial se ha transformado en una estructura tabular robusta y fiable.

Resumen del Pipeline de Datos



```
data.to_csv('dist_renta_hogares_limpio.csv', index=False)
```

index=False
para máxima
compatibilidad.

Conclusiones y Siguietes Pasos

Conclusiones Clave



Integridad

Recuperación de filas con datos numéricos corruptos mediante Regex.

```
# re.findall(r'\d+', corrupt_data) #
```



Eficiencia

Reducción drástica del uso de memoria mediante tipos categóricos.



Analítica

Habilitación de análisis temporal y geoespacial gracias a las nuevas variables.

Siguientes Pasos: El dataset '`dist_renta_hogares_limpio.csv`' está validado y listo para ser ingestados en modelos de Machine Learning o dashboards de visualización.

→ Datos listos para la acción.