

PRÁCTICA GUIADA DE ANÁLISIS EXPLORATORIO DE DATOS (AED) CON PYTHON

ANÁLISIS DE DATOS EN PYTHON

ALUMNO: PABLO CHAMORRO GONZALEZ-RIPOLL
pchagon360@g.educaand.es


25 de octubre de 2025

Tutorial paso a paso que describe cómo trabajar con Anaconda para el análisis de datos, usando de ejemplo un conjunto de datos reales sobre alojamientos turísticos en Barcelona que provienen de la plataforma Inside Airbnb.

- Pasos seguidos:
 - Configuración e Importación de Librerías
 - Importación del Conjunto de Datos
 - Análisis Descriptivo Inicial
 - Visualización de Distribuciones
 - Ajuste de Tipos de Datos
 - Detección y Tratamiento de Datos Ausentes
 - Detección de Valores Atípicos
 - Análisis de Correlación
 - Generación de Informe Automatizado

0. Configuración e Importación de Librerías

Debo **importar las librerías** que usaré para el análisis de datos en el código fuente con sus correspondientes alias para codificar más rápido al usarlas:



```
1 # Librerías fundamentales para análisis de datos
2 import pandas as pd          # Manipulación de datos en formato tabla
3 import numpy as np           # Cálculos numéricos y estadísticos
4 import matplotlib.pyplot as plt # Visualización básica (gráficos)
5 import seaborn as sns        # Visualización avanzada y estética
6 import os                    # Operaciones con archivos y rutas
7
```

1. Importación del Conjunto de Datos

En <https://insideairbnb.com/get-the-data/> uso **ctrl+f** para buscar Barcelona y descargar el archivo *listings.csv* para guardarlo en la carpeta de trabajo (**debe ser el mismo directorio donde se encuentre el archivo *importacion.py***).

En *importacion.py* **añado una variable** que contendrá toda la información del csv manipulada en formato tabla usando pandas:


```
8 # Cargar el archivo listings.csv descargado de Inside Airbnb
9 df = pd.read_csv('listings.csv')
10
```

2. Análisis Descriptivo Inicial

La primera línea **mostrará las dos primeras filas del dataframe** (la variable df que he creado). Permiten inspeccionar de un vistazo cómo están organizados los datos (columnas y tipo de valores) y comprobar que se cargan correctamente.

La segunda línea **imprime una separación visual** en consola (=====). Es útil para mostrar diferentes bloques de información seguidos.

Código:



```
1 # Librerías fundamentales para análisis de datos
2 import pandas as pd      # Manipulación de datos en formato tabla
3 import numpy as np       # Cálculos numéricos y estadísticos
4 import matplotlib.pyplot as plt # Visualización básica (gráficos)
5 import seaborn as sns    # Visualización avanzada y estética
6 import os               # Operaciones con archivos y rutas
7
8 # Cargar el archivo listings.csv descargado de Inside Airbnb
9 df = pd.read_csv('listings.csv')
10
11 # Vista preliminar de los datos (dos primeras líneas)
12 print(df.head(2))
13 print("="*100)
14
15 # Información general del DataFrame
16 print(df.info())
17 print("="*100)
18
19 # Estadísticas descriptivas de las variables numéricas
20 print(df.describe())
21 print("="*100)
22
```

Resultado de la ejecución:

```
(base) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>python importacion.py
Matplotlib is building the font cache; this may take a moment.
   id      name ... number_of_reviews_ltm  license
0  18674  Huge flat for 8 people close to Sagrada Familia ...      6  HUTB-002062
1  23197  Forum CCIB DeLuxe, Spacious, Large Balcony, relax ...     10  HUTB005057

[2 rows x 18 columns]
=====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 18927 entries, 0 to 18926
Data columns (total 18 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0    id                                     18927 non-null  int64
1    name                                  18927 non-null  object
2    host_id                               18927 non-null  int64
3    host_name                             18924 non-null  object
4    neighbourhood_group                   18927 non-null  object
5    neighbourhood                         18927 non-null  object
6    latitude                             18927 non-null  float64
7    longitude                            18927 non-null  float64
8    room_type                             18927 non-null  object
9    price                                14913 non-null  float64
10   minimum_nights                        18927 non-null  int64
11   number_of_reviews                     18927 non-null  int64
12   last_review                           13929 non-null  object
13   reviews_per_month                     13929 non-null  float64
14   calculated_host_listings_count        18927 non-null  int64
15   availability_365                       18927 non-null  int64
16   number_of_reviews_ltm                 18927 non-null  int64
17   license                               12598 non-null  object
dtypes: float64(4), int64(7), object(7)
memory usage: 2.6+ MB
None
=====
count    id      host_id ...  availability_365  number_of_reviews_ltm
mean    5.644774e+17  2.007217e+08 ...      189.396629      11.485497
std     5.586685e+17  2.027743e+08 ...      125.983317      22.548024
min     1.867400e+04  3.073000e+03 ...           0.000000           0.000000
25%     2.842925e+07  1.142567e+07 ...           75.000000           0.000000
50%     6.396171e+17  1.329791e+08 ...          204.000000           1.000000
75%     1.112177e+18  3.579465e+08 ...          305.000000          15.000000
max     1.440887e+18  7.007030e+08 ...          365.000000          753.000000

[8 rows x 11 columns]
=====
```

Para ejecutar el código he usado el **Prompt de Anaconda** apuntando al directorio del archivo a ejecutar. De esta forma carga localmente los módulos necesarios.

Ejecución del código y resultado:

Usando el Prompt de Anaconda, **navego al directorio de trabajo con cd y luego ejecuto el script con python**. (tutorial de instalación de Anaconda:

<https://www.aprendemachinelearning.com/instalar-ambiente-de-desarrollo-python-anaconda-para-aprendizaje-automatico/>). **La palabra entre paréntesis que precede la ruta al**

archivo (base) nos indica que Anaconda ha activado un entorno de ejecución en nuestro directorio de trabajo.

Matplotlib comienza a cargar en caché la información y muestra una tabla de 2 filas y 18 columnas con un montón de datos que no sé qué significan por ahora. Luego se imprime la separación (=====).

A continuación, pandas crea una tabla de 18927 entradas y muestra 18 filas de datos. Intuyo que esto (el DataFrame) es similar a los metadatos de un archivo SQL en los que se muestran nombres de columnas, tipos, etc. Otra separación.

Por último, el método *.describe()* crea una tabla cuyos datos parecen estar relacionados con 8 alojamientos (id, id del dueño, disponibilidad a lo largo del año y número de reseñas). Una última separación y fin de la ejecución.

3. Visualización de Distribuciones


Las siguientes líneas **capturan las columnas numéricas** en la variable `numeric_columns` y generan el histograma “Distribución de Variables Numéricas” **iterando por los datos capturados con un bucle for** usando la función *enumerate()*. Luego se usa el método *.tight_layout()* que intuyo que está relacionado con el aspecto visual del histograma y por último se usa el método *.show()* que supongo que muestra el propio histograma creado.

Al ejecutar de nuevo el script se crean varias gráficas.

Código:

```
23 # Selección de columnas numéricas
24 numeric_columns = df.select_dtypes(include=[np.number]).columns
25
26 # Visualización con histogramas
27 n = len(numeric_columns)
28 n_rows = 3
29 n_cols = min(n, 3)
30
31 fig, axes = plt.subplots(n_rows=n_rows, n_cols=n_cols, figsize=(15, 5*n_rows))
32 fig.suptitle('Distribución de Variables Numéricas', fontsize=16)
33 axes = axes.flatten()
34
35 for i, col in enumerate(numeric_columns[:len(axes)]):
36     ax = axes[i]
37     df[col].hist(ax=ax, bins=50, edgecolor='black')
38     ax.set_title(f'Distribución de {col}')
39     ax.set_xlabel(col)
40     ax.set_ylabel('Frecuencia')
41
42 plt.tight_layout(rect=[0, 0.03, 1, 0.95])
43 plt.show()
44
```

Gráficas:



Nota: En VSCode no se me colorean ni autocompletan las funciones usadas.

Solucionar esto más adelante (probar crear un entorno virtual para VSCode con los

módulos necesarios instalados con pip, que creo que es lo equivalente a lo que hace el Prompt de Anaconda al activar un entorno).

4. Ajuste de Tipos de Datos

Convierto “neighbourhood” y “room_type” al tipo *category* aplicando el método `.astype('category')`:

```
45 # Conversión de variables categóricas
46 df['neighbourhood'] = df['neighbourhood'].astype('category')
47 df['room_type'] = df['room_type'].astype('category')
48
```

5. Detección y Tratamiento de Datos Ausentes

Usando los métodos `.isna()` y `.sum()` cuento los valores nulos por columna y los muestro. Luego junto con `.mean()` y `.round()` muestro el porcentaje de valores perdidos. Luego elimino las columnas que están medio vacías. La cuarta operación no la comprendo. Esta forma de usar Python me recuerda bastante a PL/SQL:

```
49 # Conteo de valores nulos
50 print("Valores perdidos por columna:")
51 print(df.isna().sum())
52
53 # Porcentaje de valores perdidos
54 print("Porcentaje de valores perdidos:")
55 print(df.isna().mean().round(2))
56
57 # Eliminación de columnas con más del 50% de valores nulos
58 df = df.loc[:, df.isna().mean() < 0.5]
59
60 # Imputación de valores numéricos con la media
61 clean_numeric_columns = df.select_dtypes(include=[np.number]).columns
62 df[clean_numeric_columns] = df[clean_numeric_columns].fillna(df[clean_numeric_columns].mean())
63
```


Llegado a este punto, las siguientes operaciones no las entiendo ya que me faltan los conceptos necesarios de estadística.

6. Detección de Valores Atípicos

Código:

```
64 # Cálculo de límites IQR
65 Q1 = df['price'].quantile(0.25)
66 Q3 = df['price'].quantile(0.75)
67 IQR = Q3 - Q1
68 lower_bound = Q1 - 1.5 * IQR
69 upper_bound = Q3 + 1.5 * IQR
70
71 # Visualización con boxplot
72 plt.figure(figsize=(8, 6))
73 sns.boxplot(x=df['price'])
74 plt.title('Boxplot de precios con outliers')
75 plt.show()
76
77 # Filtrado de datos sin outliers
78 df_without_outliers = df[(df['price'] >= lower_bound) & (df['price'] <= upper_bound)]
79
```

Gráfico:




7. Análisis de Correlación

Código:

```
80 # Matriz de correlación
81 correlation = df.select_dtypes(include=[np.number]).corr()
82
83 # Mapa de calor
84 plt.figure(figsize=(10, 8))
85 sns.heatmap(correlation, annot=True, cmap='coolwarm', center=0, square=True, linewidths=.5, cbar_kws={"shrink": .5})
86 plt.title('Matriz de correlación entre variables numéricas')
87 plt.show()
88
```

Gráfico:



8. Generación de Informe Automatizado

Usando *ProfileReport* genero un informe automatizado en formato HTML

Código:

```
89 # Generación de informe con YData Profiling
90 from ydata_profiling import ProfileReport
91
92 report = ProfileReport(df, title='Informe EDA Airbnb Barcelona')
93 report.to_file('reporte_airbnb_barcelona.html')
94
```

Al ejecutar el código con el Prompt de Anaconda me sale el error *ModuleNotFoundError*, ya que no tengo instalado el módulo *ydata_profiling*. Procedo a instalarlo de manera manual en el entorno de Anaconda. Primero listo los entornos disponibles:

```
(base) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>conda env list

# conda environments:
#
base                  * C:\Users\arque\anaconda3
                     c:\Users\arque\Anaconda3
```

Observo que estoy trabajando en el entorno base. Voy a crear un nuevo entorno llamado *analisis_datos*:

```
(base) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>conda create -n analisis_datos python=3.10
3 channel Terms of Service accepted
Retrieving notices: done
Channels:
- defaults
Platform: win-64
Collecting package metadata (repodata.json): done
Solving environment: done
```

Observo que se descargan paquetes nuevos y una lista de todos los paquetes que se instalan en mi nuevo entorno. **Al elegir la versión 3.10 de Python me aseguro de tener plena compatibilidad con *ydata_profiling* y *pandas*.**

Activo mi nuevo entorno:

```
(base) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>conda activate analisis_datos
(analisis_datos) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>
```

Ahora aparece entre paréntesis al comienzo del Prompt.

Procedo a instalar las herramientas que necesito para este proyecto:

```
(analisis_datos) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>conda install jupyter pandas matplotlib seaborn scikit-learn
3 channel Terms of Service accepted
Channels:
- defaults
Platform: win-64
Collecting package metadata (repodata.json): done
Solving environment: done
```

Se muestran los cientos de paquetes que se van a instalar. Ahora entiendo la importancia de usar entornos controlados para tener control sobre las herramientas que se usarán en cada proyecto.

A continuación uso pip para instalar *ydata-profiling* ya que no está en los repositorios de Conda, solucionando así el problema que tuve al ejecutar el script:

```
(analisis_datos) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0> pip install ydata-profiling
```

Se instala todo exitosamente.

Para verificar la instalación creo éste script:


```
informe2.py > ...
1  import pandas as pd
2  from ydata_profiling import ProfileReport
3
4  # Leer el archivo CSV
5  df = pd.read_csv("listings.csv")
6
7  # Generar el informe
8  profile = ProfileReport(df, title="Informe EDA Airbnb Barcelona", explorative=True)
9
10 # Exportar el informe a HTML
11 profile.to_file("reporte_airbnb_barcelona.html")
12
```

Ejecuto en el Prompt de Anaconda lo siguiente para lanzar Jupyter Notebook:

```
(analisis_datos) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>jupyter notebook
```

Se abre una instancia de mi navegador (Librewolf) que apunta a localhost por el puerto 8888 mostrando los archivos de mi directorio de trabajo. Seleccione el script creado (informe2.py) y pulso el botón Open. Se abre un editor de código fuente. Ahora entiendo

que Jupyter Notebook es un editor de texto que se ejecuta en un navegador. Ya creé antes el script usando VSCode. Se muestra así:




```
jupyter informe2.py Last Checkpoint: 8 minutes ago

File Edit View Settings Help

1 import pandas as pd
2 from ydata_profiling import ProfileReport
3
4 # Leer el archivo CSV
5 df = pd.read_csv("listings.csv")
6
7 # Generar el informe
8 profile = ProfileReport(df, title="Informe EDA Airbnb Barcelona", explorative=True)
9
10 # Exportar el informe a HTML
11 profile.to_file("reporte_airbnb_barcelona.html")
12
```

Ejecuto el script informe2.py y observo que se ha creado con éxito el archivo reporte_airbnb_barcelona.html.




```
(analisis_datos) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>python informe2.py
Upgrade to ydata-sdk
Improve your data and profiling with ydata-sdk, featuring data quality scoring, redundancy detection, outlier identification, text validation, and synthetic data generation.
Register at https://ydata.ai/register
100%|████████████████████████████████████████████████████████████████████████████████| 18/18 [00:00<00:00, 44.32it/s]
Summarize dataset: 100%|████████████████████████████████████████████████████████████████████████████████| 149/149 [00:14<00:00, 10.56it/s, Completed]
Generate report structure: 100%|████████████████████████████████████████████████████████████████████████████████| 1/1 [00:08<00:00, 8.03s/it]
Render HTML: 100%|████████████████████████████████████████████████████████████████████████████████| 1/1 [00:00<00:00, 1.56it/s]
Export report to file: 100%|████████████████████████████████████████████████████████████████████████████████| 1/1 [00:00<00:00, 35.84it/s]
```

Al abrir éste se muestran todos los datos y gráficos creados.

Extra: Guardar entorno como plantilla (environment.yml)

Por último creo un archivo de configuración YAML con toda la información del entorno analisis_datos:



```
(analisis_datos) C:\Documentos\PabloPython\Análisis_de_Datos_en_Python\practica0>conda env export > environment.yml
```

Con este archivo puedo **crear un entorno idéntico en otro equipo** simplemente ejecutando en el Prompt de Conda: *conda env create -f environment.yml*

Con ésta práctica he llegado a las siguientes conclusiones:

- La creación de gráficos de esta práctica me recuerda a los frameworks que se usan para crear interfaces gráficas de usuario.
- El manejo de datos me recuerda a PL/SQL, ya que los métodos y funciones se parecen, aunque con Python todo es mucho más sencillo y limpio, y menos verboso.
- Este documento me servirá como guía durante el curso para usar los comandos de Anaconda y proceder a la hora de crear gráficos e informes. Ya iré aprendiendo los conceptos de estadística, el uso de las librerías aquí usadas y sus funciones más adelante.